TRƯỜNG ĐẠI HỌC KỸ THUẬT – CÔNG NGHỆ CẦN THƠ

KHOA CÔNG NGHỆ THÔNG TIN

-----ꕥ📖ꕥ-----

DỰ ÁN BÀI TẬP LỚN

HỌC PHẦN: MÁY HỌC

Ngành: Khoa Học Máy Tính

XÂY DỰNG HỆ THỐNG GỢI Ý PHIM ỨNG DỤNG MACHINE LEARNING

Giảng viên hướng dẫn:
ThS. Lê Anh Nhã Uyên

Sinh viên thực hiện:

Nguyễn Minh Huy	**MSSV: KHMT2411062**
Đoàn Tấn Lực	**MSSV: KHMT2411058**
Nguyễn Lâm Nguyên	**MSSV: KHMT2411007**
Ngô Thị Cẩm Như	**MSSV: KHMT2411018**
Nguyễn Trọng Phúc	**MSSV: KHMT2411034**
Trần Thị Tú Trinh	**MSSV: KHMT2411001**

Cần Thơ, Ngày , Tháng , Năm 2026

LỜI CẢM ƠN
MỤC LỤC
DANH MỤC BẢNG BIỂU
DANH MỤC HÌNH ẢNH

CHƯƠNG 1: TỔNG QUAN VỀ ĐỀ TÀI

1.1. Lý do lựa chọn đề tài

Hiện nay, sự đa dạng về số lượng, thể loại và nội dung phim mang đến cho người dùng nhiều lựa chọn giải trí. Tuy nhiên, việc tìm kiếm một bộ phim phù hợp với sở thích cá nhân có thể mất nhiều thời gian khi người dùng phải lựa chọn giữa quá nhiều nội dung. Vì vậy, xây dựng một hệ thống gợi ý phim có khả năng khai thác lịch sử đánh giá và đưa ra các đề xuất phù hợp là một bài toán có ý nghĩa thực tế, góp phần hỗ trợ người dùng lựa chọn phim và nâng cao trải nghiệm khám phá nội dung.

Trong lĩnh vực Machine Learning, hệ thống gợi ý là một hướng ứng dụng tiêu biểu của việc khai thác dữ liệu để hỗ trợ ra quyết định. Thông qua lịch sử đánh giá phim, hệ thống có thể xác định những điểm tương đồng trong sở thích của người dùng và sử dụng các mối quan hệ này để tạo ra đề xuất được cá nhân hóa. Nhóm lựa chọn nghiên cứu và triển khai hai phương pháp User-Based Collaborative Filtering và Content-Based Filtering. Việc kết hợp hai phương pháp này giúp nhóm có cơ sở so sánh, đối chứng cách tính độ tương đồng, dự đoán đánh giá và xây dựng danh sách phim gợi ý một cách toàn diện.

Bên cạnh đó, bộ dữ liệu MovieLens Latest Small do GroupLens Research cung cấp (gồm 100.836 lượt đánh giá của 610 người dùng đối với 9.742 bộ phim) tạo điều kiện thuận lợi cho việc thực nghiệm và triển khai đề tài. Dữ liệu đánh giá có cấu trúc rõ ràng và quy mô phù hợp với một dự án học phần, giúp nhóm thực hiện quá trình xử lý, phân tích và đánh giá mô hình trong điều kiện nguồn lực có hạn. Việc sử dụng bộ dữ liệu này cũng cho phép nhóm kiểm chứng phương pháp trên dữ liệu thực tế thay vì chỉ minh họa bằng các ví dụ giả định.

Về mặt học tập, đề tài tạo cơ hội vận dụng kiến thức Machine Learning vào một bài toán cụ thể, đồng thời rèn luyện kỹ năng xử lý dữ liệu, xây dựng mô hình, đánh giá kết quả và phát triển giao diện minh họa. Qua đó, nhóm có thể hiểu rõ hơn khả năng ứng dụng cũng như những hạn chế của phương pháp lọc cộng tác trong việc cá nhân hóa đề xuất cho người dùng.

Từ những lý do trên, nhóm lựa chọn đề tài "Xây dựng hệ thống gợi ý phim sử dụng Machine Learning". Đề tài vừa đáp ứng nhu cầu hỗ trợ lựa chọn phim theo sở thích cá nhân, vừa phù hợp với mục tiêu và phạm vi của học phần. Sản phẩm được định hướng là một hệ thống thử nghiệm (prototype), phục vụ học tập, nghiên cứu và minh họa khả năng gợi ý phim dựa trên lịch sử đánh giá của người dùng.

1.2. Phát biểu bài toán

1.2.1. Bối cảnh bài toán

Hiện nay có số lượng lớn phim thuộc nhiều thể loại và nội dung khác nhau. Người dùng có thể gặp khó khăn trong việc lựa chọn phim phù hợp với sở thích và nhu cầu cá nhân.

1.2.2. Nhu cầu thực tế và vấn đề cần giải quyết

Hệ thống tập trung hỗ trợ người dùng lựa chọn phim phù hợp bằng cách:

Phân tích thông tin phim và dữ liệu tương tác của người dùng.

Xác định mối quan hệ giữa người dùng và phim.

Dự đoán mức độ phù hợp của phim đối với từng người dùng.

Dựa trên kết quả dự đoán để đề xuất phim phù hợp.

1.2.3. Dữ liệu đầu vào

Thông tin phim: mã phim (movieId), tên phim (title) và thể loại (genres). Năm phát hành có thể được trích xuất từ tên phim khi cần.

Lịch sử đánh giá mã người dùng (userId), mã phim (movieId) và điểm đánh giá (rating) từ 0,5 đến 5 sao, với bước 0,5.

Thời điểm đánh giá của trường timestamp được sử dụng để phân chia dữ liệu theo thời gian và kiểm soát rò rỉ thông tin tương lai.

1.2.4. Kết quả đầu ra

Đầu ra của hệ thống là danh sách Top-N phim được đề xuất cho từng người dùng. Các phim được xếp hạng dựa trên điểm phù hợp với hồ sơ sở thích trong phương pháp Content-based Filtering hoặc điểm đánh giá dự đoán trong phương pháp User-Based Collaborative Filtering. Đối với chức năng gợi ý phim tương tự, đầu ra là danh sách các phim có độ tương đồng cao về thể loại với phim được lựa chọn.

1.2.5. Đối tượng dự đoán

Hệ thống xem xét từng người dùng và từng bộ phim.

Dự đoán mức độ phù hợp của bộ phim đối với người dùng.

1.2.6. Thời điểm dự đoán

Hệ thống thực hiện dự đoán khi người dùng yêu cầu xem phim đề xuất.

Dựa trên những thông tin đã có của người dùng và bộ phim tại thời điểm đó.

1.2.7. Hành động sau dự đoán

Dự đoán mức độ phù hợp → Xếp hạng phim → Đề xuất phim.

Những bộ phim được dự đoán phù hợp hơn sẽ được ưu tiên hiển thị.

1.2.8. Kiểm soát rò rỉ dữ liệu

Chỉ sử dụng thông tin đã có tại thời điểm dự đoán.

Không sử dụng đánh giá hoặc tương tác xảy ra sau đó.

Đảm bảo mô hình không sử dụng thông tin từ tương lai để đưa ra dự đoán.

1.2.9. Bài toán Machine Learning

Đề tài giải quyết bài toán gợi ý phim bằng hai phương pháp Content-based Filtering và User-Based Collaborative Filtering trên bộ dữ liệu MovieLens Latest Small.

Content-based Filtering khai thác thể loại phim và hồ sơ sở thích được xây dựng từ lịch sử đánh giá để tính mức độ phù hợp của phim với người dùng.

User-Based Collaborative Filtering khai thác sự tương đồng giữa người dùng dựa trên lịch sử đánh giá để dự đoán điểm đánh giá cho các phim chưa được người dùng đánh giá.

Kết quả của mỗi phương pháp được sử dụng để xếp hạng và đề xuất danh sách Top-N phim. Hai phương pháp được so sánh trên cùng cách phân chia dữ liệu theo thời gian và cùng các chỉ số đánh giá chất lượng danh sách gợi ý.

Quy trình tổng quát: Dữ liệu trước mốc dự đoán → Xây dựng mô hình → Tính điểm phù hợp hoặc dự đoán điểm đánh giá → Xếp hạng → Đề xuất Top-N phim.

1.3. Mục tiêu và phạm vi nghiên cứu

1.3.1. Mục tiêu đề tài

Đề tài "Xây dựng hệ thống gợi ý phim sử dụng Machine Learning" được thực hiện với mục tiêu nghiên cứu, xây dựng và đánh giá một hệ thống có khả năng khai thác thông tin về phim và lịch sử đánh giá của người dùng để phân tích sở thích cá nhân, từ đó đưa ra các đề xuất phim phù hợp và có tính cá nhân hóa. Trong phạm vi đề tài, hệ thống tập trung áp dụng các phương pháp Machine Learning phổ biến trong bài toán gợi ý, tiến hành xử lý dữ liệu, xây dựng mô hình, đánh giá hiệu quả đề xuất và triển khai chức năng gợi ý phim cho người dùng dựa trên dữ liệu hiện có.

Các mục tiêu cụ thể của đề tài bao gồm:

Nghiên cứu cơ sở lý thuyết về hệ thống gợi ý: Tìm hiểu khái niệm, nguyên lý hoạt động, quy trình xây dựng và các phương pháp phổ biến được áp dụng trong bài toán gợi ý.

Thu thập và tiền xử lý dữ liệu: Sử dụng tập dữ liệu MovieLens, thực hiện các bước làm sạch, kiểm tra dữ liệu thiếu, chuẩn hóa và tổ chức dữ liệu để phục vụ cho quá trình huấn luyện và đánh giá mô hình.

Xây dựng mô hình gợi ý phim: Nghiên cứu và áp dụng các phương pháp Machine Learning phù hợp, tập trung vào Collaborative Filtering và Content-based Filtering.

Xây dựng chức năng gợi ý cá nhân hóa: Đề xuất danh sách Top-N phim phù hợp với từng người dùng dựa trên lịch sử đánh giá và đặc điểm sở thích.

Xây dựng chức năng gợi ý phim tương đồng: Xác định và đề xuất các bộ phim có đặc điểm nội dung tương tự với một bộ phim mà người dùng đang quan tâm.

Đánh giá hiệu quả mô hình: Sử dụng các chỉ số đánh giá phù hợp như MAE, RMSE và, khi cần thiết, các chỉ số đánh giá danh sách gợi ý như Precision@N, Recall@N để phân tích chất lượng của mô hình.

Xây dựng giao diện minh họa: Phát triển giao diện web ở mức prototype, cho phép người dùng tìm kiếm phim, xem thông tin cơ bản và trải nghiệm kết quả gợi ý một cách trực quan.

Thông qua các mục tiêu trên, đề tài hướng đến việc xây dựng một mô hình gợi

ý phim có khả năng hoạt động trên dữ liệu thực tế, đồng thời giúp vận dụng kiến thức về Machine Learning, xử lý dữ liệu và phát triển ứng dụng web vào một bài toán cụ thể.

1.3.2. Phạm vi đề tài

1.3.2.1. Phạm vi về dữ liệu

Đề tài sử dụng bộ dữ liệu MovieLens Latest Small do GroupLens Research cung cấp, tập trung khai thác hai tệp movies.csv và ratings.csv.

Các nhóm dữ liệu chính được sử dụng gồm:

Thông tin người dùng: Mã định danh người dùng (userId), được xác định từ lịch sử đánh giá.

Thông tin phim: Mã phim (movieId), tên phim (title) và thể loại (genres). Năm phát hành có thể được trích xuất từ tên phim khi cần.

Lịch sử đánh giá: Mã người dùng (userId), mã phim (movieId), điểm đánh giá (rating) và thời điểm đánh giá (timestamp).

Thể loại phim được sử dụng cho phương pháp Content-based Filtering; lịch sử đánh giá phục vụ phương pháp User-Based Collaborative Filtering và xây dựng hồ sơ sở thích người dùng. Trường timestamp được giữ lại để phân chia dữ liệu theo thời gian và kiểm soát rò rỉ thông tin tương lai.

Dữ liệu được sử dụng cho quá trình tiền xử lý, phân tích, huấn luyện, kiểm thử và đánh giá các mô hình gợi ý. Đề tài tập trung xử lý dữ liệu ở quy mô phù hợp với mục đích nghiên cứu và thử nghiệm, chưa hướng đến xử lý dữ liệu thời gian thực hoặc dữ liệu quy mô rất lớn trong môi trường thương mại.

1.3.2.2. Phạm vi về phương pháp và thuật toán

Đề tài tập trung triển khai và so sánh hai phương pháp gợi ý phim trên bộ dữ liệu MovieLens Latest Small:

User-Based Collaborative Filtering: Khai thác lịch sử đánh giá để xác định những người dùng có sở thích tương đồng, từ đó dự đoán điểm đánh giá và đề xuất danh sách Top-N phim cho từng người dùng.

Content-based Filtering: Sử dụng thể loại để biểu diễn đặc trưng phim, xác định

các phim có nội dung tương đồng và xây dựng hồ sơ sở thích từ những phim người dùng đã đánh giá cao. Hồ sơ này được sử dụng để xếp hạng và đề xuất Top-N phim phù hợp.

Hai phương pháp được đánh giá trên cùng cách phân chia dữ liệu theo thời gian, cùng tập phim ứng viên và cùng các chỉ số đánh giá danh sách gợi ý. Những thông tin dùng để xây dựng mô hình và lựa chọn tham số phải có trước mốc dự đoán.

1.3.2.3. Phạm vi về chức năng hệ thống

Hệ thống tập trung triển khai các chức năng chính sau:

Lựa chọn người dùng: Chọn mã người dùng có lịch sử đánh giá trong dữ liệu để thực hiện gợi ý cá nhân hóa.

Tìm kiếm phim: Tìm phim theo tên hoặc thể loại.

Xem thông tin phim: Hiển thị tên phim, thể loại và năm phát hành nếu trích xuất được từ tên phim.

Gợi ý cá nhân hóa: Đề xuất danh sách Top-N phim bằng User-Based Collaborative Filtering hoặc Content-based Filtering, dựa trên lịch sử đánh giá đã có của người dùng.

Gợi ý phim tương tự: Sử dụng Content-based Filtering để đề xuất các phim có thể loại tương đồng với phim được lựa chọn.

Hiển thị kết quả: Trình bày danh sách phim đề xuất và thông tin cơ bản qua giao diện web được xây dựng bằng Streamlit.

So sánh kết quả thực nghiệm: Tổng hợp kết quả đánh giá hai phương pháp trên cùng cách phân chia dữ liệu theo thời gian và cùng các chỉ số đánh giá danh sách gợi ý.

1.3.2.4. Phạm vi đánh giá

Đề tài tập trung đánh giá chất lượng danh sách gợi ý cá nhân hóa của User-Based Collaborative Filtering và Content-based Filtering thông qua hai chỉ số chính:

Precision@N: Tỷ lệ phim phù hợp trong N phim được đề xuất cho người dùng.

Recall@N: Tỷ lệ phim phù hợp được đề xuất trong tổng số phim phù hợp của người dùng ở tập kiểm thử, thuộc tập phim ứng viên đủ điều kiện.

Phim được xem là phù hợp khi điểm đánh giá thực tế đạt ngưỡng yêu thích đã xác định. Giá trị N và ngưỡng yêu thích được quy định thống nhất trước khi đánh giá trên tập kiểm thử.

Hai phương pháp được so sánh trên cùng tập người dùng, cùng tập phim ứng viên và cùng cách phân chia dữ liệu theo thời gian. Người dùng không có phim phù hợp trong tập kiểm thử được thống kê riêng và không đưa vào phép tính Recall@N trung bình.

Ngoài ra, MAE và RMSE được sử dụng để đánh giá sai số dự đoán điểm của User-Based Collaborative Filtering. Hai chỉ số này không áp dụng trực tiếp cho điểm tương đồng của Content-based Filtering.

Kết quả thực nghiệm được sử dụng để phân tích ưu điểm, hạn chế và mức độ phù hợp của từng phương pháp. Chức năng gợi ý phim tương tự được kiểm tra riêng về khả năng hoạt động và tính tương đồng thể loại; không đồng nhất kết quả này với đánh giá gợi ý cá nhân hóa.

1.3.2.5. Những nội dung ngoài phạm vi nghiên cứu

Do giới hạn về thời gian, nguồn lực và mục tiêu nghiên cứu, đề tài tập trung triển khai hai phương pháp User-Based Collaborative Filtering và Content-based Filtering ở mức prototype. Đề tài không triển khai Item-Based Collaborative Filtering, Matrix Factorization/SVD, các mô hình Deep Learning hoặc mô hình ngôn ngữ lớn; không giải quyết toàn diện bài toán Cold-start đối với người dùng mới và phim mới.

Các nội dung phân tích chuyên sâu dữ liệu đa phương tiện như poster, hình ảnh, âm thanh, trailer phim và xử lý kịch bản hoặc văn bản dài bằng kỹ thuật xử lý ngôn ngữ tự nhiên nâng cao cũng nằm ngoài phạm vi nghiên cứu. Ngoài ra, đề tài không khai thác dữ liệu từ nhiều nguồn hoặc sử dụng thông tin ngữ cảnh như vị trí, thời gian, thiết bị và mạng xã hội để cá nhân hóa gợi ý. Trường timestamp chỉ được sử dụng để phân chia dữ liệu theo thời gian và kiểm soát rò rỉ dữ liệu, không dùng để mô hình hóa sự thay đổi sở thích của người dùng. Hệ thống không xử lý dữ liệu liên tục theo thời gian thực, không triển khai trên hạ tầng phân tán quy mô lớn và không

tối ưu hóa để phục vụ số lượng lớn người dùng đồng thời.

Sản phẩm của đề tài được xây dựng chủ yếu ở mức prototype, phục vụ mục đích học tập, nghiên cứu, thực nghiệm và minh họa khả năng ứng dụng Machine Learning trong bài toán gợi ý phim.

1.4. Đối tượng nghiên cứu

1.4.1. Xác định đối tượng chính

Đối tượng nghiên cứu của đề tài là quá trình phân tích mức độ tương đồng về sở thích xem phim giữa những người dùng nhằm xây dựng hệ thống gợi ý các bộ phim có khả năng phù hợp với nhu cầu và sở thích của từng người dùng. Trong đó đề tài tập trung nghiên cứu các đối tượng chính

Người dùng (User) được đại diện bằng mã định danh, có lịch sử đánh giá các bộ phim với mức điểm khác nhau.

Phim (Movie) được đại diện bằng mã phim, tên phim và thể loại.

Mức độ yêu thích (Rating) thể hiện sự đánh giá của người dùng đối với một bộ phim, thông qua thang điểm từ 0.5 đến 5 sao.

Mối quan hệ giữa người dùng và phim thể hiện thông qua lịch sử đánh giá, làm cơ sở xác định những người dùng có sở thích tương đồng.



1.4. Công cụ và kế hoạch thực hiện

Đề tài sử dụng Python để xử lý dữ liệu, xây dựng hai phương pháp User-Based Collaborative Filtering và Content-based Filtering, đánh giá kết quả và phát triển giao diện minh họa.

Jupyter Notebook hoặc Google Colab được sử dụng để tổ chức các bước thực nghiệm, chạy chương trình và ghi nhận kết quả xử lý dữ liệu, biểu đồ và chỉ số đánh giá.

Pandas được sử dụng để đọc hai tệp ratings.csv và movies.csv, kiểm tra kiểu dữ liệu, giá trị thiếu, bản ghi trùng lặp và liên kết thông tin phim với đánh giá theo movieId. Thư viện này cũng phục vụ thống kê dữ liệu và phân chia các bản ghi theo timestamp.

NumPy hỗ trợ biểu diễn và xử lý ma trận đánh giá, vector thể loại phim và hồ sơ sở thích của người dùng. scikit-learn được sử dụng để mã hóa danh sách thể loại thành vector nhị phân, tính Cosine Similarity và tính các chỉ số sai số dự đoán điểm. Nhóm xây dựng quy trình lựa chọn người dùng tương đồng, dự đoán điểm và xếp

hạng phim dựa trên các công cụ này.

Matplotlib được sử dụng để trực quan hóa phân bố điểm đánh giá, số lượt đánh giá theo người dùng và phim, phân bố thể loại và kết quả so sánh hai phương pháp. Nguồn dữ liệu được lựa chọn là MovieLens Latest Small do GroupLens Research cung cấp. Đề tài tập trung khai thác thông tin phim và lịch sử đánh giá để thực hiện gợi ý cá nhân hóa và gợi ý phim tương tự.

Streamlit được sử dụng để xây dựng giao diện web minh họa. Giao diện cho phép lựa chọn người dùng có lịch sử đánh giá, lựa chọn phương pháp gợi ý, xem danh sách Top-N phim và chọn một phim để tìm các phim tương đồng về thể loại. Kết quả hiển thị gồm tên phim, thể loại và điểm gợi ý tương ứng với từng phương pháp.

1.5.2. Kế hoạch dự kiến thực hiện

Kế hoạch thực hiện gồm các giai đoạn từ xác định bài toán, chuẩn bị dữ liệu, xây dựng hai phương pháp đến đánh giá và hoàn thiện giao diện minh họa.

Giai đoạn 1: Nghiên cứu bài toán và phương pháp nhóm tìm hiểu nguyên lý của User-Based Collaborative Filtering và Content-based Filtering, xác định dữ liệu đầu vào, đầu ra và các chức năng của hệ thống. Đầu ra chính là danh sách Top-N phim cá nhân hóa; chức năng bổ sung là gợi ý phim tương tự dựa trên thể loại.

Giai đoạn 2: Thu thập và kiểm tra dữ liệu nhóm tải bộ MovieLens Latest Small, ghi nhận phiên bản sử dụng và đọc hai tệp ratings.csv, movies.csv. Các bước kiểm tra gồm cấu trúc dữ liệu, kiểu dữ liệu, giá trị thiếu, bản ghi trùng lặp, phạm vi điểm đánh giá và tính nhất quán của movieId giữa hai tệp. Nhóm thống kê quy mô dữ liệu ban đầu và ghi nhận những thay đổi sau khi làm sạch.

Giai đoạn 3: Phân chia dữ liệu theo thời gian, các bản ghi đánh giá được sắp xếp theo timestamp và chia thành tập huấn luyện, xác thực và kiểm thử bằng các mốc thời gian chung. Tập huấn luyện nằm trước tập xác thực và tập xác thực nằm trước tập kiểm thử. Các bản ghi có cùng thời điểm không được tách qua hai giai đoạn.
Việc phân chia được thực hiện trước khi xây dựng ma trận đánh giá, tính độ tương đồng hoặc tạo hồ sơ sở thích. Trong giai đoạn lựa chọn mô hình, các phép tính này chỉ sử dụng tập huấn luyện.

Nhóm quy định tập phim ứng viên dựa trên những phim đã xuất hiện trong dữ liệu được phép sử dụng trước mốc dự đoán. Các trường hợp người dùng hoặc phim chưa có dữ liệu huấn luyện được thống kê và xử lý riêng.

Giai đoạn 4: Phân tích dữ liệu và xây dựng đặc trưng nhóm phân tích tập huấn luyện để khảo sát phân bố điểm, số lượt đánh giá của người dùng và phim, mức độ thưa của ma trận và phân bố thể loại.

Đối với User-Based Collaborative Filtering, nhóm xây dựng ma trận người dùng – phim từ các điểm đánh giá trong tập huấn luyện. Những ô chưa có đánh giá được xem là dữ liệu chưa quan sát, không phải điểm đánh giá bằng 0.

Đối với Content-based Filtering, thể loại phim được mã hóa thành vector nhị phân. Hồ sơ sở thích được xây dựng từ vector thể loại của những phim mà người dùng đã đánh giá cao trong tập huấn luyện. Tên phim được giữ lại để hiển thị kết quả.

Giai đoạn 5: Triển khai hai phương pháp User-Based Collaborative Filtering: tính độ tương đồng giữa người dùng, lựa chọn những người dùng tương đồng và dự đoán điểm cho các phim chưa được người dùng đánh giá. Content-based Filtering tính mức độ phù hợp giữa hồ sơ sở thích và vector thể loại của phim để tạo danh sách gợi ý cá nhân hóa. Phương pháp này đồng thời tính độ tương đồng giữa các vector phim để thực hiện chức năng gợi ý phim tương tự.

Hai phương pháp cùng xếp hạng trên một tập phim ứng viên và loại các phim người dùng đã đánh giá trong lịch sử được sử dụng để tạo gợi ý.

Giai đoạn 6: Lựa chọn tham số và đánh giá nhóm sử dụng tập xác thực để lựa chọn tham số của mô hình, chẳng hạn như số người dùng tương đồng trong User-Based Collaborative Filtering. Giá trị N, ngưỡng điểm thể hiện sự yêu thích và quy tắc đánh giá được chốt trước khi kiểm tra trên tập kiểm thử.

Sau khi chốt cấu hình, nhóm có thể xây dựng lại mô hình trên dữ liệu huấn luyện và xác thực, sau đó đánh giá trên giai đoạn kiểm thử phía sau. Các đánh giá thuộc tập kiểm thử không được sử dụng để xây dựng hoặc điều chỉnh mô hình. Precision@N và Recall@N được sử dụng để so sánh chất lượng gợi ý cá nhân hóa của hai phương pháp trên cùng tập người dùng và phim ứng viên. MAE và RMSE được tính bổ sung

cho phần dự đoán điểm của User-Based Collaborative Filtering.

Nhóm báo cáo số người dùng đủ điều kiện đánh giá, số trường hợp không có phim phù hợp trong tập kiểm thử và số trường hợp không thể tạo dự đoán. Chức năng gợi ý phim tương tự được kiểm tra riêng về khả năng hoạt động và mức độ tương đồng về thể loại.

Giai đoạn 7: Xây dựng giao diện minh họa nhóm tích hợp hai phương pháp vào giao diện Streamlit. Người dùng có thể chọn mã người dùng và phương pháp để nhận Top-N phim cá nhân hóa, hoặc chọn một phim để xem các phim có thể loại tương đồng.

Giao diện hiển thị thông tin cơ bản của phim và kết quả đánh giá thực nghiệm. Nhóm kiểm tra các tình huống thiếu lịch sử đánh giá, không tìm thấy phim và không đủ phim để tạo danh sách Top-N.

Giai đoạn 8: Hoàn thiện báo cáo và mã nguồn, nhóm tổng hợp kết quả, phân tích ưu điểm và hạn chế của hai phương pháp, rà soát sự thống nhất giữa dữ liệu, thuật toán, chức năng và chỉ số đánh giá.

Mã nguồn được tổ chức theo các bước xử lý dữ liệu, xây dựng mô hình, đánh giá và giao diện. Phiên bản dữ liệu, mốc chia thời gian, tham số và cách chạy chương trình được ghi lại để có thể tái lập thực nghiệm. Nếu tiếp tục điều chỉnh mô hình sau khi xem kết quả kiểm thử, nhóm cần một giai đoạn kiểm thử mới để đánh giá cuối cùng.

1.6. Phương pháp nghiên cứu

Đề tài sử dụng phương pháp nghiên cứu tài liệu, phân tích dữ liệu và thực nghiệm so sánh để xây dựng và đánh giá hệ thống gợi ý phim.

Nghiên cứu tài liệu: Nhóm tìm hiểu các tài liệu về hệ thống gợi ý, tập trung vào nguyên lý của User-Based Collaborative Filtering và Content-based Filtering. Đồng thời, nhóm nghiên cứu cấu trúc bộ dữ liệu MovieLens Latest Small, các chỉ số đánh giá và cách kiểm soát rò rỉ dữ liệu theo thời gian để xác định quy trình thực nghiệm phù hợp.

Phân tích và xử lý dữ liệu nhóm kiểm tra cấu trúc, kiểu dữ liệu, giá trị thiếu,

bản ghi trùng lặp và mối liên kết giữa thông tin phim với lịch sử đánh giá. Dữ liệu được phân chia theo thời gian trước khi xây dựng các thành phần của mô hình. Trên tập huấn luyện, nhóm phân tích phân bố điểm đánh giá, mức độ tương tác và độ thưa của ma trận người dùng – phim. Kết quả phân tích được sử dụng để xây dựng ma trận đánh giá, mã hóa thể loại và tạo hồ sơ sở thích người dùng.

Thực nghiệm và so sánh Nhóm triển khai User-Based Collaborative Filtering và Content-based Filtering trên cùng bộ dữ liệu. Các tham số được lựa chọn bằng tập xác thực; kết quả cuối cùng được đánh giá trên tập kiểm thử ở giai đoạn thời gian phía sau.

Hai phương pháp được so sánh bằng Precision@N và Recall@N trên cùng tập người dùng và phim ứng viên. MAE và RMSE được sử dụng bổ sung để đánh giá khả năng dự đoán điểm của User-Based Collaborative Filtering. Kết quả được phân tích nhằm xác định ưu điểm, hạn chế và mức độ phù hợp của từng phương pháp.

Xây dựng và kiểm tra sản phẩm minh họa Nhóm xây dựng giao diện Streamlit để minh họa chức năng gợi ý cá nhân hóa và gợi ý phim tương tự. Các chức năng được kiểm tra với những trường hợp đầu vào khác nhau để xác nhận khả năng hoạt động và sự thống nhất giữa dữ liệu, mô hình và kết quả hiển thị. Phiên bản dữ liệu, mốc phân chia thời gian, tham số và quy trình chạy chương trình được ghi nhận nhằm hỗ trợ tái lập thực nghiệm.

CHƯƠNG 2: CƠ SỞ LÝ THUYẾT

2.1. Tổng quan về Machine Learning

2.1.1. Khái niệm Machine Learning

Machine Learning (học máy) là một lĩnh vực thuộc trí tuệ nhân tạo (Artificial Intelligence – AI), tập trung nghiên cứu và phát triển các phương pháp cho phép máy tính học hỏi từ dữ liệu, nhận diện các quy luật và đưa ra dự đoán hoặc quyết định mà không cần lập trình tường minh toàn bộ quy tắc xử lý.

Khác với phương pháp lập trình truyền thống, trong đó con người xây dựng sẵn các quy tắc để máy tính thực hiện, Machine Learning sử dụng dữ liệu để xác định những mối quan hệ tiềm ẩn giữa các đối tượng. Thông qua quá trình học và phân tích dữ liệu, hệ thống có thể đưa ra kết quả đối với những trường hợp chưa từng được quan sát.

Trong lĩnh vực giải trí, Machine Learning được ứng dụng rộng rãi để xây dựng hệ thống gợi ý phim, âm nhạc và các nội dung số. Các hệ thống này có khả năng phân tích lịch sử tương tác, đánh giá và sở thích của người dùng nhằm đề xuất những nội dung phù hợp với từng cá nhân.

Đối với đề tài xây dựng hệ thống gợi ý phim, Machine Learning được ứng dụng để khai thác dữ liệu đánh giá phim và đặc trưng thể loại. Từ đó, hệ thống xác định mức độ tương đồng giữa những người dùng hoặc giữa các bộ phim, làm cơ sở dự đoán mức độ yêu thích và xây dựng danh sách phim đề xuất.

2.1.2. Các phương pháp học máy phổ biến

Machine Learning được chia thành nhiều phương pháp học khác nhau, trong đó ba nhóm phổ biến là học có giám sát, học không giám sát và học tăng cường.

a. Học có giám sát (Supervised Learning)

Học có giám sát là phương pháp sử dụng dữ liệu có nhãn để xây dựng mô hình dự đoán. Trong quá trình học, mô hình phân tích mối quan hệ giữa dữ liệu đầu vào và kết quả đầu ra đã biết nhằm tìm ra quy luật phù hợp.

Hai dạng bài toán phổ biến của học có giám sát gồm:

Phân loại(Classification): Dự đoán đối tượng thuộc một nhóm hoặc một lớp xác định.

Hồi quy (Regression): Dự đoán một giá trị liên tục dựa trên những đặc trưng đầu vào.

Trong hệ thống gợi ý phim, bài toán dự đoán điểm đánh giá có thể được xem là một bài toán dự đoán giá trị số. Chẳng hạn, hệ thống sử dụng lịch sử đánh giá để ước lượng mức điểm mà người dùng có thể dành cho một bộ phim chưa được đánh giá.

b. Học không giám sát (Unsupervised Learning)

Học không giám sát là phương pháp khai thác dữ liệu không có nhãn mục tiêu nhằm phát hiện cấu trúc, sự tương đồng hoặc các nhóm đối tượng có đặc điểm gần nhau. Một số kỹ thuật thường gặp là phân cụm dữ liệu, giảm chiều dữ liệu và phân tích độ tương đồng.

Trong hệ thống gợi ý phim, việc xác định những người dùng có lịch sử đánh giá tương tự hoặc những bộ phim có đặc trưng nội dung gần nhau thể hiện cách khai thác cấu trúc và quan hệ trong dữ liệu. Tuy nhiên, không phải mọi phương pháp tính độ tương đồng đều được xem là một thuật toán học không giám sát theo nghĩa chặt chẽ.

c. Học tăng cường (Reinforcement Learning)

Học tăng cường là phương pháp trong đó một tác nhân học cách lựa chọn hành động thông qua quá trình tương tác với môi trường. Tác nhân nhận phần thưởng hoặc tín hiệu phản hồi để điều chỉnh chiến lược nhằm tối đa hóa tổng phần thưởng trong dài hạn. Phương pháp này có thể được ứng dụng trong những hệ thống gợi ý có khả năng liên tục điều chỉnh đề xuất theo hành vi tương tác của người dùng.

Tuy nhiên, trong phạm vi đề tài, nhóm không triển khai học tăng cường mà tập trung nghiên cứu các phương pháp gợi ý dựa trên độ tương đồng giữa dữ liệu người dùng và phim.

2.1.3. Quy trình xây dựng một hệ thống Machine Learning

Một hệ thống Machine Learning thường được xây dựng thông qua các giai đoạn chính, bao gồm thu thập dữ liệu, tiền xử lý dữ liệu, xây dựng đặc trưng, lựa chọn mô hình, đánh giá và triển khai.

Trước tiên, dữ liệu cần được thu thập từ nguồn phù hợp với bài toán. Sau đó, hệ thống thực hiện kiểm tra và làm sạch dữ liệu nhằm loại bỏ hoặc xử lý những thông tin không hợp lệ, thiếu hoặc trùng lặp.

Tiếp theo, dữ liệu được chuyển đổi thành dạng biểu diễn phù hợp với phương pháp tính toán. Quá trình này có thể bao gồm xây dựng ma trận đánh giá, mã hóa đặc trưng phim và xác định hồ sơ sở thích của người dùng.

Sau bước chuẩn bị dữ liệu, mô hình được xây dựng và lựa chọn tham số phù hợp. Chất lượng mô hình cần được đánh giá trên dữ liệu không sử dụng trong quá trình xây dựng mô hình, nhằm xác định khả năng dự đoán và gợi ý đối với những tương tác chưa được quan sát.

Cuối cùng, mô hình được tích hợp vào ứng dụng để cung cấp kết quả cho người dùng.

Trong đề tài, quy trình này được áp dụng trên bộ dữ liệu MovieLens Latest Small. Nhóm sử dụng thông tin phim và lịch sử đánh giá, phân chia dữ liệu theo thời gian thành tập huấn luyện, tập xác thực và tập kiểm thử. Hai phương pháp Content-Based Filtering và User-Based Collaborative Filtering được xây dựng, đánh giá và tích hợp vào giao diện minh họa bằng Streamlit.

2.1.4. Vai trò của Machine Learning trong hệ thống gợi ý phim

Machine Learning đóng vai trò quan trọng trong việc phân tích dữ liệu và hỗ trợ cá nhân hóa nội dung đề xuất. Thay vì hiển thị một danh sách phim giống nhau cho tất cả người dùng, hệ thống có thể khai thác dữ liệu đã có để đưa ra những gợi ý phù hợp với sở thích riêng của từng cá nhân.

Đối với hệ thống gợi ý phim, Machine Learning giúp hỗ trợ phân tích lịch sử đánh giá, xác định sự tương đồng giữa người dùng, khai thác đặc trưng nội dung và dự đoán mức độ phù hợp của từng bộ phim.

Trong phạm vi đề tài, nhóm lựa chọn hai phương pháp chính là Content-Based Filtering dùng để khai thác đặc trưng thể loại phim và hồ sơ sở thích người dùng để xác định mức độ phù hợp. User-Based Collaborative Filtering dùng để phân tích lịch sử đánh giá nhằm tìm kiếm những người dùng có sở thích tương đồng và dự đoán điểm đánh giá.

Việc nghiên cứu hai phương pháp này giúp nhóm hiểu rõ khả năng khai thác dữ liệu trong hệ thống gợi ý, đồng thời tạo cơ sở thực nghiệm để so sánh chất lượng đề xuất và phân tích những hạn chế của từng phương pháp.

2.2. Tổng quan về hệ thống gợi ý

2.2.1. Khái niệm hệ thống gợi ý

Hệ thống gợi ý (Recommender System) là hệ thống có chức năng phân tích dữ liệu liên quan đến người dùng và đối tượng nhằm dự đoán mức độ quan tâm, từ đó đề xuất những nội dung hoặc sản phẩm phù hợp với từng cá nhân.

Hệ thống gợi ý thường được ứng dụng trong thương mại điện tử, giải trí trực tuyến, mạng xã hội và các nền tảng cung cấp nội dung số. Thông qua việc khai thác lịch sử tương tác, đánh giá hoặc đặc điểm nội dung, hệ thống hỗ trợ người dùng tìm kiếm những đối tượng phù hợp trong một tập dữ liệu có số lượng lớn.

Trong lĩnh vực phim ảnh, hệ thống gợi ý hỗ trợ người dùng lựa chọn những bộ phim có khả năng phù hợp với sở thích cá nhân. Thay vì phải tìm kiếm thủ công trong danh sách nhiều bộ phim, người dùng có thể tham khảo các đề xuất được hệ thống sắp xếp theo mức độ phù hợp.

2.2.2. Các thành phần cơ bản của hệ thống gợi ý

Một hệ thống gợi ý thường bao gồm ba thành phần chính là người dùng, đối tượng được gợi ý và dữ liệu tương tác.

Người dùng (User): Là đối tượng nhận các đề xuất từ hệ thống. Mỗi người dùng được xác định bằng một mã định danh riêng. Trong đề tài, thuộc tính userId được sử dụng để phân biệt các người dùng trong bộ dữ liệu.

Phim (Movie): Là đối tượng được hệ thống xem xét và đề xuất. Mỗi bộ phim được xác định bằng movieId và có các thuộc tính như tên phim (title), thể loại

(genres).

Dữ liệu đánh giá (Rating): Thể hiện mức độ yêu thích hoặc đánh giá của người dùng đối với một bộ phim. Trong bộ dữ liệu MovieLens Latest Small, điểm đánh giá có giá trị từ 0,5 đến 5 sao. Dữ liệu này là cơ sở để phân tích sở thích và xây dựng mô hình gợi ý.

Bên cạnh đó, hệ thống còn sử dụng thời điểm đánh giá (timestamp) để xác định thứ tự thời gian của các tương tác, phục vụ việc phân chia dữ liệu và kiểm soát rò rỉ thông tin trong quá trình thực nghiệm.

Mối quan hệ giữa người dùng và phim có thể được biểu diễn dưới dạng ma trận người dùng - phim, trong đó mỗi hàng đại diện cho một người dùng, mỗi cột đại diện cho một bộ phim và giá trị tại các ô là điểm đánh giá đã quan sát được.

2.2.3. Nguyên lý hoạt động của hệ thống gợi ý

Nguyên lý hoạt động của hệ thống gợi ý dựa trên việc khai thác thông tin đã có để ước lượng mức độ phù hợp giữa người dùng và những đối tượng chưa được đánh giá.

Trước tiên, hệ thống thu thập và xử lý dữ liệu đầu vào, bao gồm thông tin phim và lịch sử đánh giá của người dùng. Các dữ liệu này được tổ chức thành dạng phù hợp để phục vụ quá trình tính toán.

Tiếp theo, hệ thống áp dụng phương pháp gợi ý để xác định các mối quan hệ trong dữ liệu. Đối với lọc cộng tác dựa trên người dùng, hệ thống so sánh lịch sử đánh giá để tìm những người dùng có sở thích tương đồng. Đối với lọc dựa trên nội dung, hệ thống so sánh đặc trưng thể loại của phim với hồ sơ sở thích người dùng.

Dựa trên kết quả phân tích, hệ thống tính điểm dự đoán hoặc điểm phù hợp cho các bộ phim ứng viên. Những bộ phim người dùng đã đánh giá trong lịch sử được sử dụng để tạo gợi ý sẽ bị loại khỏi danh sách ứng viên.

Cuối cùng, hệ thống sắp xếp những bộ phim còn lại theo điểm số giảm dần và lựa chọn N phim đứng đầu để tạo danh sách Top-N.

2.2.4. Các phương pháp xây dựng hệ thống gợi ý

Có nhiều phương pháp được sử dụng để xây dựng hệ thống gợi ý, trong đó

phổ biến gồm:

Content-Based Filtering (lọc dựa trên nội dung): Phương pháp đề xuất các đối tượng có đặc trưng nội dung tương đồng với những đối tượng mà người dùng từng yêu thích. Trong bài toán gợi ý phim, các đặc trưng có thể là thể loại, từ khóa hoặc thông tin mô tả phim. Đề tài tập trung sử dụng thể loại phim để biểu diễn nội dung.

Collaborative Filtering (lọc cộng tác): Phương pháp khai thác dữ liệu tương tác của nhiều người dùng để xác định mối quan hệ và tạo đề xuất. Phương pháp này có thể tiếp cận theo hướng tương đồng giữa người dùng hoặc tương đồng giữa các đối tượng. Trong đề tài, nhóm lựa chọn User-Based Collaborative Filtering.

Hybrid Recommendation (gợi ý kết hợp): Phương pháp kết hợp nhiều kỹ thuật gợi ý nhằm khai thác ưu điểm của các phương pháp riêng lẻ. Ví dụ, kết hợp thông tin nội dung phim với lịch sử đánh giá của nhiều người dùng.

Trong phạm vi nghiên cứu, nhóm triển khai độc lập Content-Based Filtering và User-Based Collaborative Filtering để đánh giá, so sánh kết quả. Hệ thống chưa xây dựng mô hình Hybrid kết hợp kết quả của hai phương pháp.

2.2.5. Những thách thức của hệ thống gợi ý

Mặc dù có khả năng hỗ trợ cá nhân hóa nội dung, hệ thống gợi ý vẫn gặp một số thách thức trong quá trình xây dựng và triển khai.

Thứ nhất, vấn đề dữ liệu thưa (Data Sparsity). Số lượng phim mà một người dùng đánh giá thường chỉ chiếm một phần nhỏ trong tổng số phim. Điều này khiến ma trận đánh giá có nhiều ô chưa quan sát, làm hạn chế khả năng xác định những người dùng tương đồng.

Thứ hai, vấn đề Cold-start. Khi người dùng mới chưa có lịch sử đánh giá hoặc phim mới chưa nhận được đánh giá, hệ thống có thể gặp khó khăn trong việc tạo đề xuất, đặc biệt đối với phương pháp lọc cộng tác.

Thứ ba, khả năng đa dạng hóa gợi ý. Nếu hệ thống chỉ ưu tiên những phim có đặc điểm quá giống với lịch sử yêu thích, danh sách gợi ý có thể thiếu sự đa dạng và hạn chế khả năng khám phá những nội dung mới.

Thứ tư, chất lượng và mức độ đầy đủ của dữ liệu. Kết quả đề xuất phụ thuộc vào lượng thông tin và đặc trưng được sử dụng. Trong trường hợp chỉ dựa vào thể loại phim, hệ thống có thể chưa phân biệt rõ những bộ phim có cùng thể loại nhưng khác nhau về nội dung, cốt truyện hoặc phong cách.

Những thách thức trên là cơ sở để nhóm phân tích ưu điểm, hạn chế của hai phương pháp và đề xuất hướng phát triển trong tương lai.

2.2.6. Ứng dụng hệ thống gợi ý trong đề tài

Trong đề tài xây dựng hệ thống gợi ý phim ứng dụng Machine Learning, hệ thống sử dụng bộ dữ liệu MovieLens Latest Small, bao gồm 610 người dùng, 9.742 bộ phim và 100.836 lượt đánh giá.

Các thông tin được khai thác chủ yếu từ hai tệp movies.csv và ratings.csv. Dữ liệu được xử lý để tạo ma trận đánh giá người dùng – phim và vector đặc trưng thể loại của phim.

Hệ thống được xây dựng với mục tiêu hỗ trợ lựa chọn người dùng, tìm kiếm phim, hiển thị thông tin phim, đề xuất Top-N phim cá nhân hóa và tìm kiếm những bộ phim tương đồng về thể loại.

Hai phương pháp Content-Based Filtering và User-Based Collaborative Filtering được triển khai riêng biệt. Kết quả gợi ý cá nhân hóa được đánh giá thông qua PrecisionN và RecallN; khả năng dự đoán điểm đánh giá của User-Based Collaborative Filtering được đánh giá bổ sung bằng MAE và RMSE.

Thông qua việc xây dựng hệ thống, nhóm có thể áp dụng kiến thức Machine Learning vào một bài toán thực tế, đồng thời phân tích khả năng cá nhân hóa nội dung và những hạn chế khi khai thác dữ liệu đánh giá phim.

2.3. Các phương pháp tiếp cận trong hệ thống gợi ý

Trong đề tài xây dựng hệ thống gợi ý phim ứng dụng Machine Learning, việc lựa chọn mô hình là một bước quan trọng nhằm xác định phương pháp phù hợp để khai thác dữ liệu, phân tích sở thích người dùng và đề xuất những bộ phim có khả năng đáp ứng nhu cầu giải trí của từng cá nhân.

Dựa trên mục tiêu nghiên cứu và đặc điểm của bộ dữ liệu MovieLens Latest

Small, nhóm lựa chọn hai phương pháp chính là Content-Based Filtering (lọc dựa trên nội dung) và User-Based Collaborative Filtering (lọc cộng tác dựa trên người dùng). Hai phương pháp được triển khai riêng biệt để đánh giá khả năng gợi ý phim và so sánh ưu điểm, hạn chế của từng phương pháp.

2.3.1. Mô hình 1 Content-Based Filtering

2.3.1.1. Khái niệm

Content-Based Filtering là phương pháp gợi ý dựa trên đặc điểm nội dung của phim và sở thích đã thể hiện của người dùng. Phương pháp này phân tích các thuộc tính mô tả phim để xác định những bộ phim có đặc điểm tương đồng với các phim mà người dùng từng yêu thích.

Trong phạm vi đề tài, nhóm sử dụng thông tin về thể loại phim trong tệp movies.csv để xây dựng đặc trưng nội dung. Ngoài ra, tài liệu cũng đề cập đến việc khai thác các thẻ mô tả trong tags.csv để bổ sung thông tin cho quá trình biểu diễn nội dung phim.

2.3.1.2. Dữ liệu đầu vào

Các dữ liệu chính phục vụ mô hình bao gồm:

movieId gồm mã định danh của bộ phim.

Title gồm tên phim, phục vụ việc hiển thị và nhận diện phim.

Genres gồm các thể loại phim, được sử dụng để xây dựng vector đặc trưng nội dung.

userId gồm mã định danh người dùng.

Rating gồm điểm đánh giá phim, được sử dụng để xác định mức độ yêu thích của người dùng.

Tag gồm thẻ mô tả phim, có thể được khai thác để bổ sung đặc trưng nội dung nếu được đưa vào phạm vi triển khai.

Trong đó, thể loại phim và lịch sử đánh giá là những thông tin quan trọng để xây dựng hồ sơ sở thích của người dùng. Tên phim chủ yếu phục vụ hiển thị kết quả, không trực tiếp tham gia tính toán độ tương đồng theo cách triển khai đã mô tả trong tài liệu.

2.3.1.3. Nguyên lý hoạt động

Mô hình Content-Based Filtering có thể được triển khai theo các bước sau:

Bước 1: trích xuất đặc trưng nội dung phim, hệ thống lấy thông tin thể loại từ cột genres trong tệp movies.csv. Vì mỗi phim có thể thuộc nhiều thể loại khác nhau, nhóm tiến hành tách chuỗi thể loại và mã hóa thành vector đặc trưng.

Tên phim	**Action**	**Comedy**	**Drama**	**Romance**
Phim A	1	0	1	0
Phim B	1	0	0	0
Phim C	0	1	0	1

Trong bảng trên, giá trị 1 biểu thị phim có thể loại tương ứng, còn giá trị 0 biểu thị phim không thuộc thể loại đó.

Cách biểu diễn này giúp chuyển dữ liệu thể loại từ dạng văn bản sang dạng số để mô hình có thể thực hiện các phép tính toán học.

Bước 2: Xây dựng hồ sơ sở thích người dùng hệ thống khai thác lịch sử đánh giá trong tệp ratings.csv để xác định những thể loại mà người dùng có xu hướng yêu thích. Chẳng hạn, nếu một người dùng thường đánh giá cao các phim thuộc thể loại Action và Adventure, hệ thống sẽ hình thành hồ sơ sở thích có mức độ ưu tiên cao đối với các thể loại này.

Hồ sơ sở thích có thể được xây dựng bằng cách tổng hợp vector thể loại của các phim được người dùng đánh giá cao trong tập huấn luyện.

Bước 3: Tính mức độ phù hợp giữa người dùng và phim sau khi xây dựng hồ sơ sở thích, hệ thống so sánh vector sở thích của người dùng với vector đặc trưng của từng phim ứng viên.

Một phương pháp có thể sử dụng là Cosine Similarity, nhằm xác định mức độ tương đồng giữa hai vector. Giá trị tương đồng càng cao thì phim càng có khả năng phù hợp với hồ sơ sở thích của người dùng.

Bước 4: Xếp hạng và tạo danh sách gợi ý hệ thống sắp xếp các phim theo điểm phù hợp giảm dần, loại bỏ những phim người dùng đã đánh giá và lựa chọn N phim đứng đầu để tạo danh sách Top-N. Ví dụ, khi người dùng yêu thích các phim hành

động và phiêu lưu, hệ thống sẽ ưu tiên đề xuất những bộ phim có đặc trưng thể loại gần với hồ sơ sở thích đó.

2.3.1.4. Ứng dụng trong đề tài

Content-Based Filtering được sử dụng cho hai chức năng chính: gợi ý phim cá nhân hóa dựa trên thể loại của những phim người dùng yêu thích. Gợi ý các bộ phim tương tự với một bộ phim được người dùng lựa chọn.

Ưu điểm của phương pháp này là có thể khai thác đặc trưng nội dung của phim để tạo đề xuất mà không nhất thiết phải dựa vào sự tương đồng giữa nhiều người dùng. Tuy nhiên, chất lượng gợi ý phụ thuộc vào mức độ đầy đủ và khả năng biểu diễn của các đặc trưng nội dung. Nếu chỉ sử dụng thể loại, hệ thống có thể chưa phân biệt được những bộ phim cùng thể loại nhưng khác nhau về cốt truyện hoặc phong cách.

2.3.2. Mô hình 2: User-Based Collaborative Filtering

2.3.2.1. Khái niệm

User-Based Collaborative Filtering là phương pháp lọc cộng tác dựa trên người dùng, hoạt động theo nguyên lý: những người dùng có lịch sử đánh giá phim tương tự nhau có thể có những sở thích tương đồng.

Thay vì chỉ xem xét đặc điểm nội dung của phim, phương pháp này khai thác mối quan hệ giữa người dùng thông qua lịch sử đánh giá. Từ đó, hệ thống xác định những người dùng có sở thích gần với người dùng mục tiêu và sử dụng thông tin đánh giá của họ để dự đoán mức độ yêu thích đối với những bộ phim mà người dùng mục tiêu chưa xem hoặc chưa đánh giá.

Trong đề tài, phương pháp này sử dụng chủ yếu dữ liệu từ tệp ratings.csv để xác định độ tương đồng giữa những người dùng và xây dựng danh sách phim gợi ý.

2.3.2.2. Dữ liệu đầu vào

Các thuộc tính chính bao gồm:

userId: Xác định người dùng.

movieId: Xác định bộ phim được đánh giá.

rating: Điểm đánh giá của người dùng đối với bộ phim.

timestamp: Thời điểm đánh giá, được sử dụng để phân chia dữ liệu theo thời gian và kiểm soát rò rỉ dữ liệu.

Trong đó, rating là thuộc tính trọng tâm để tính toán độ tương đồng và dự đoán điểm đánh giá. Hai thuộc tính userId và movieId được sử dụng để tổ chức dữ liệu thành ma trận người dùng - phim. Trường timestamp phục vụ quá trình phân chia dữ liệu, không được sử dụng trực tiếp làm đặc trưng tính điểm của mô hình.

2.3.2.3. Nguyên lý hoạt động

Mô hình User-Based Collaborative Filtering có thể được triển khai theo các bước sau:

Bước 1: Xây dựng ma trận người dùng, phim từ dữ liệu trong ratings.csv, hệ thống xây dựng ma trận đánh giá với:

Hàng đại diện cho người dùng.

Cột đại diện cho bộ phim.

Giá trị tại mỗi ô là điểm đánh giá của người dùng đối với bộ phim tương ứng. Ví dụ:

Người dùng	**Phim A**	**Phim B**	**Phim C**	**Phim D**
U1	5,0	4,5	2,0	Chưa đánh giá
U2	4,5	5,0	Chưa đánh giá	4,0
U3	1,5	Chưa đánh giá	4,5	Chưa đánh giá

Ma trận này thể hiện mối quan hệ giữa người dùng và phim thông qua điểm đánh giá.

Những ô chưa có điểm đánh giá được xem là dữ liệu chưa quan sát, không được tự động gán bằng 0. Đây là điểm quan trọng nhằm tránh làm sai lệch kết quả tính toán độ tương đồng.

Bước 2: Tính độ tương đồng giữa những người dùng.

Sau khi xây dựng ma trận đánh giá, hệ thống tính độ tương đồng giữa người dùng mục tiêu và những người dùng khác. Một phương pháp được đề cập trong tài liệu là Cosine Similarity. Phép tính này xem xét các vector đánh giá của người dùng trên những bộ phim mà cả hai cùng đánh giá. Nếu hai người dùng thường đánh giá

các bộ phim giống nhau với mức điểm gần nhau, hệ thống có thể xác định họ có mức độ tương đồng cao.

Ví dụ, người dùng U1 và U2 đều đánh giá cao Phim A và Phim B. Điều này cho thấy hai người có thể có sở thích tương đồng, vì vậy thông tin đánh giá của U2 có thể được sử dụng để hỗ trợ dự đoán mức độ yêu thích của U1 đối với những bộ phim U1 chưa đánh giá.

Bước 3: Lựa chọn những người dùng tương đồng.

Sau khi tính toán độ tương đồng, hệ thống sắp xếp những người dùng khác theo mức độ tương đồng với người dùng mục tiêu. Từ danh sách này, mô hình lựa chọn một nhóm người dùng có độ tương đồng cao nhất để làm cơ sở dự đoán.

Số lượng người dùng được lựa chọn là một tham số cần xem xét trong quá trình xây dựng mô hình. Nhóm có thể thử nghiệm các giá trị khác nhau và sử dụng tập xác thực để lựa chọn cấu hình phù hợp.

Bước 4: Dự đoán điểm đánh giá.

Đối với những bộ phim mà người dùng mục tiêu chưa đánh giá, hệ thống sử dụng thông tin đánh giá từ nhóm người dùng tương đồng để ước lượng mức điểm mà người dùng mục tiêu có thể đưa ra. Những người dùng có mức độ tương đồng cao hơn có thể được trao trọng số lớn hơn trong quá trình dự đoán.

Kết quả dự đoán giúp hệ thống xác định những bộ phim có khả năng được người dùng mục tiêu yêu thích.

Bước 5: Xếp hạng và tạo danh sách gợi ý.

Sau khi dự đoán điểm đánh giá cho các phim ứng viên, hệ thống sắp xếp các bộ phim theo điểm dự đoán giảm dần. Những phim đã được người dùng mục tiêu đánh giá sẽ bị loại khỏi danh sách đề xuất. Các bộ phim còn lại được lựa chọn để tạo danh sách Top-N.

User-Based Collaborative Filtering thực hiện quá trình gợi ý dựa trên sự tương đồng trong hành vi đánh giá giữa những người dùng, thay vì chỉ dựa vào đặc điểm thể loại của phim.

2.3.4. Ứng dụng trong đề tài

Trong hệ thống gợi ý phim, User-Based Collaborative Filtering được sử dụng để: phân tích sự tương đồng giữa những người dùng dựa trên lịch sử đánh giá.

Dự đoán điểm đánh giá cho những bộ phim người dùng chưa đánh giá.

Xếp hạng và đề xuất danh sách Top-N phim phù hợp.

Đánh giá sai số dự đoán thông qua các chỉ số MAE và RMSE.

Ưu điểm của phương pháp này là có thể khai thác sở thích chung giữa những người dùng mà không cần mô tả chi tiết nội dung từng bộ phim. Tuy nhiên, phương pháp phụ thuộc vào lịch sử tương tác. Khi người dùng hoặc phim có ít dữ liệu đánh giá, việc tính toán độ tương đồng và đưa ra dự đoán có thể gặp khó khăn

2.3.5 Kết luận phần tìm mô hình

Qua quá trình nghiên cứu và xác định phương pháp, nhóm lựa chọn Content-Based Filtering và User-Based Collaborative Filtering để xây dựng hệ thống gợi ý phim ứng dụng Machine Learning.

Content-Based Filtering tập trung khai thác đặc trưng nội dung phim, đặc biệt là thể loại, kết hợp với lịch sử đánh giá để xây dựng hồ sơ sở thích và đề xuất những bộ phim phù hợp. Phương pháp này cũng hỗ trợ chức năng tìm kiếm các phim tương tự với một bộ phim được lựa chọn.

Trong khi đó, User-Based Collaborative Filtering khai thác lịch sử đánh giá để xác định những người dùng có sở thích tương đồng, từ đó dự đoán điểm đánh giá và xếp hạng những bộ phim có khả năng phù hợp với người dùng mục tiêu.

Việc triển khai hai phương pháp riêng biệt tạo cơ sở để nhóm phân tích sự khác nhau giữa gợi ý dựa trên nội dung và gợi ý dựa trên hành vi người dùng. Thông qua quá trình thực nghiệm và đánh giá bằng các chỉ số phù hợp, nhóm có thể xác định ưu điểm, hạn chế và mức độ đáp ứng mục tiêu của từng phương pháp.

Kết quả của phần tìm mô hình là cơ sở cho các bước tiếp theo, bao gồm xây dựng mô hình, lựa chọn tham số, đánh giá hiệu quả gợi ý và tích hợp vào giao diện minh họa của hệ thống.

2.4. Các thuật toán ứng dụng trong hệ thống gợi ý

2.4.1. Thuật toán Cosine Similarity

Cosine Similarity là phương pháp đo mức độ tương đồng giữa hai vector dựa trên cosin của góc tạo bởi chúng trong không gian vector.

Công thức tính:

$$"sim"("A"",""B")" = "\frac{\sum^{"i"} "A"\quad "B"}{\sqrt{\sum^{"i"}\quad}\ \sqrt{\sum^{"i"}}}$$

Trong đó:

A, B: Hai vector cần so sánh.

A_i, B_i: Giá trị tại vị trí thứ i của mỗi vector.

n: Số chiều của vector.

Giá trị Cosine Similarity càng cao cho thấy hai vector càng có hướng gần nhau. Đối với vector thể loại nhị phân không âm, độ tương đồng nằm trong khoảng từ 0 đến 1. Giá trị 1 thể hiện hai vector cùng hướng, trong khi giá trị 0 cho thấy chúng không chia sẻ đặc trưng đang xét.

Trong đề tài, Cosine Similarity được ứng dụng vào hai trường hợp.

Trường hợp 1: Tính độ tương đồng giữa các bộ phim.

Mỗi bộ phim được biểu diễn bằng vector thể loại. Nếu hai bộ phim có nhiều thể loại chung, độ tương đồng giữa hai vector thường cao hơn.

Ví dụ:

Phim A thuộc thể loại Action và Comedy, được biểu diễn bằng vector A = (1, 1, 0).

Phim B thuộc thể loại Action, được biểu diễn bằng vector B = (1, 0, 0).

Khi đó:

$$"sim"("A"",""B")" = "\frac{"1"}{\sqrt{"2""}\times ""1"}" \approx ""0"",""707"$$

Kết quả cho thấy hai bộ phim có sự tương đồng về thể loại do cùng thuộc nhóm Action.

Trường hợp 2: Tính độ tương đồng giữa người dùng.

Hệ thống sử dụng vector điểm đánh giá trên các bộ phim mà hai người dùng cùng đánh giá để xác định mức độ tương đồng trong sở thích.

Những người dùng có lịch sử đánh giá gần nhau có thể nhận được độ tương đồng cao và được lựa chọn để hỗ trợ dự đoán điểm cho người dùng mục tiêu.

Khi tính toán, hệ thống cần đảm bảo chỉ sử dụng các đánh giá thuộc dữ liệu được phép tại thời điểm dự đoán. Trường hợp không có đủ phim được cả hai người dùng đánh giá cần được xử lý riêng.

2.4.2. Thuật toán mã hóa đặc trưng thể loại phim

Để thực hiện Content-Based Filtering, dữ liệu thể loại phim cần được chuyển đổi từ dạng văn bản thành dạng số.

Trong tệp movies.csv, một bộ phim có thể thuộc nhiều thể loại, được phân tách bằng ký tự "|". Do đó, nhóm sử dụng phương pháp mã hóa Multi-Hot Encoding để biểu diễn các thể loại thành vector nhị phân.

Giả sử hệ thống xét bốn thể loại gồm Action, Comedy, Drama và Romance, các bộ phim được biểu diễn như sau:

Phim	Action	Comedy	Drama	Romance
A	1	1	0	0
B	1	0	1	0
C	0	1	0	1

Trong đó, giá trị 1 biểu thị bộ phim thuộc thể loại tương ứng và giá trị 0 biểu thị bộ phim không thuộc thể loại đó.

Sau khi mã hóa, mỗi phim được biểu diễn dưới dạng một vector có số chiều tương ứng với tổng số thể loại được xét.

Các vector này được sử dụng để tính Cosine Similarity giữa các phim và xây dựng hồ sơ sở thích của người dùng.

Ưu điểm của cách biểu diễn này là đơn giản, dễ triển khai và phù hợp với cấu trúc dữ liệu MovieLens. Tuy nhiên, phương pháp chỉ phản ánh sự xuất hiện của thể loại mà chưa thể hiện đầy đủ nội dung hoặc mức độ quan trọng của từng thể loại trong một bộ phim.

2.4.3. Thuật toán xây dựng hồ sơ sở thích người dùng

Trong Content-Based Filtering, hồ sơ sở thích người dùng được xây dựng dựa trên đặc trưng của những bộ phim mà người dùng từng đánh giá cao.

Giả sử người dùng u đã đánh giá cao một tập phim L(u). Mỗi phim i được biểu diễn bởi vector thể loại x_i.

Một cách xây dựng hồ sơ sở thích là lấy trung bình các vector thể loại của những phim được yêu thích:

$$"P"\ \ " = "\frac{"1"}{|"L"("u")|}\sum^{"i""\in"}"x"$$

Trong đó:

P_u: Vector hồ sơ sở thích của người dùng u.

L(u): Tập phim được người dùng u đánh giá cao trong tập dữ liệu được phép sử dụng.

x_i: Vector đặc trưng thể loại của phim i.

|L(u)|: Số lượng phim được sử dụng để xây dựng hồ sơ.

Vector P_u phản ánh mức độ xuất hiện của từng thể loại trong danh sách các phim được người dùng yêu thích.

Sau khi xây dựng hồ sơ sở thích, hệ thống tính độ phù hợp giữa người dùng u và phim ứng viên j bằng Cosine Similarity:

$$"S"("u"",""j")" = ""sim"("P"\ \ ",""x"\ \ )$$

Giá trị S(u,j) càng cao cho thấy đặc trưng thể loại của phim j càng gần với hồ sơ sở thích của người dùng u.

Hệ thống sử dụng kết quả này để sắp xếp và đề xuất những bộ phim có mức độ phù hợp cao nhất.

Trong trường hợp người dùng không có phim đạt ngưỡng yêu thích hoặc vector hồ sơ sở thích bằng không, hệ thống cần có quy tắc xử lý riêng thay vì thực hiện phép tính Cosine Similarity không xác định.

2.4.4. Thuật toán K-Nearest Neighbors trong lọc cộng tác

K-Nearest Neighbors (KNN) là phương pháp xác định K đối tượng gần nhất

với đối tượng mục tiêu dựa trên một độ đo tương đồng hoặc khoảng cách.

Trong User-Based Collaborative Filtering, KNN được sử dụng để lựa chọn những người dùng có lịch sử đánh giá tương đồng nhất với người dùng mục tiêu.

Quá trình thực hiện gồm các bước:

Bước 1: Xây dựng ma trận người dùng – phim từ dữ liệu đánh giá thuộc tập huấn luyện.

Bước 2: Tính độ tương đồng giữa người dùng mục tiêu và những người dùng khác bằng Cosine Similarity trên các phim cùng được đánh giá.

Bước 3: Sắp xếp những người dùng theo độ tương đồng giảm dần.

Bước 4: Lựa chọn tối đa K người dùng có độ tương đồng cao nhất và đáp ứng điều kiện dữ liệu để hỗ trợ dự đoán.

Bước 5: Sử dụng điểm đánh giá của những người dùng được lựa chọn để dự đoán mức độ yêu thích đối với các phim ứng viên.

Tham số K ảnh hưởng đến kết quả dự đoán. Nếu K quá nhỏ, dự đoán có thể phụ thuộc nhiều vào một số ít người dùng. Ngược lại, nếu K quá lớn, hệ thống có thể đưa thêm những người dùng có mức tương đồng thấp, làm giảm tính cá nhân hóa.

Vì vậy, nhóm cần phải thử nghiệm các giá trị K khác nhau trên tập xác thực để lựa chọn cấu hình phù hợp trước khi đánh giá trên một tập kiểm thử.

2.4.5. Thuật toán dự đoán điểm đánh giá bằng trung bình có trọng số

Sau khi lựa chọn những người dùng tương đồng, hệ thống cần ước lượng điểm đánh giá của người dùng mục tiêu đối với các phim chưa được đánh giá.

Một cách tiếp cận là sử dụng trung bình có trọng số dựa trên độ tương đồng giữa những người dùng.

Công thức dự đoán:

$$\hat{r}_{u,i} = \frac{\sum_{v \in N_k(u,i)} sim(u,v) \cdot r_{v,i}}{\sum_{v \in N_k(u,i)} |sim(u,v)|}$$

Trong đó:

$\hat{r}_{u,i}$: Điểm đánh giá dự đoán của người dùng u đối với phim i.

$N_k(u,i)$: Tập tối đa K người dùng tương đồng với u và đã đánh giá phim

i.

sim(u,v): Độ tương đồng giữa người dùng u và người dùng v.

$r_{v,i}$: Điểm đánh giá thực tế của người dùng v đối với phim i.

Công thức cho phép những người dùng có mức độ tương đồng cao đóng góp trọng số lớn hơn vào kết quả dự đoán.

Ví dụ, giả sử người dùng U1 chưa đánh giá phim A. Hai người dùng tương đồng U2 và U3 có thông tin:

U2 đánh giá phim A là 5 sao, độ tương đồng với U1 bằng 0,9.

U3 đánh giá phim A là 3 sao, độ tương đồng với U1 bằng 0,6.

Điểm dự đoán được tính như sau:

$$"^{""1""}_{""U""}" = "\frac{""0"",""9"" \times ""5"" + ""0"",""6"" \times ""3"}{""0"",""9"" + ""0"",""6"}" = ""4"",""2"$$

Kết quả dự đoán là 4,2 sao, thể hiện phim A có khả năng phù hợp với sở thích của người dùng U1 theo mô hình đang xét.

Ví dụ trên chỉ mang tính minh họa nguyên lý, không phải kết quả thực nghiệm từ bộ dữ liệu MovieLens.

Trong quá trình triển khai, mô hình cần xử lý trường hợp không tìm được người dùng tương đồng có đánh giá phim ứng viên hoặc tổng trọng số ở mẫu số bằng 0. Những trường hợp không thể đưa ra dự đoán hợp lệ cần được thống kê khi đánh giá mô hình.

2.4.6. Thuật toán xếp hạng và đề xuất Top-N phim

Top-N Recommendation là quá trình lựa chọn N bộ phim có điểm dự đoán hoặc điểm phù hợp cao nhất để đề xuất cho người dùng.

Đối với Content-Based Filtering, điểm xếp hạng được xác định bằng mức độ tương đồng giữa hồ sơ sở thích người dùng và vector đặc trưng thể loại của phim.

Đối với User-Based Collaborative Filtering, điểm xếp hạng được xác định dựa trên kết quả dự đoán điểm đánh giá từ những người dùng tương đồng.

Quy trình đề xuất Top-N gồm:

Bước 1: Xác định người dùng mục tiêu và tập phim ứng viên hợp lệ.

Bước 2: Loại bỏ những bộ phim mà người dùng đã đánh giá trong lịch sử được sử dụng để tạo gợi ý.

Bước 3: Tính điểm phù hợp hoặc điểm đánh giá dự đoán cho từng phim ứng viên.

Bước 4: Sắp xếp danh sách phim theo điểm số giảm dần.

Bước 5: Lựa chọn N bộ phim có điểm số cao nhất và trả về danh sách đề xuất.

Kết quả đầu ra có thể bao gồm tên phim, thể loại và điểm số tương ứng với phương pháp được lựa chọn.

Để đánh giá công bằng, cả hai phương pháp cần sử dụng cùng tập phim ứng viên, cùng độ dài danh sách N và cùng cách phân chia dữ liệu theo thời gian.

2.4.7. Kết luận

Các thuật toán được nghiên cứu trong phần này tạo cơ sở tính toán cho hai phương pháp gợi ý phim của đề tài.

Đối với Content-Based Filtering, kỹ thuật mã hóa Multi-Hot Encoding được sử dụng để biểu diễn thể loại phim, kết hợp với việc xây dựng hồ sơ sở thích và Cosine Similarity nhằm xác định mức độ phù hợp giữa người dùng và phim.

Đối với User-Based Collaborative Filtering, Cosine Similarity hỗ trợ xác định mức độ tương đồng giữa người dùng, KNN hỗ trợ lựa chọn những người dùng gần nhất và công thức trung bình có trọng số được sử dụng để dự đoán điểm đánh giá.

Kết quả tính toán của cả hai phương pháp được sử dụng để tạo danh sách Top-N phim. Những danh sách này là cơ sở cho việc đánh giá chất lượng gợi ý bằng PrecisionN và RecallN, trong khi MAE và RMSE được sử dụng bổ sung để đánh giá sai số dự đoán điểm của User-Based Collaborative Filtering.

Việc nghiên cứu và áp dụng các thuật toán trên giúp hệ thống thực hiện quá trình gợi ý có cơ sở tính toán rõ ràng, đồng thời tạo điều kiện so sánh ưu điểm và hạn chế của từng phương pháp trong quá trình thực nghiệm.

2.5. Các độ đo đánh giá

Để đánh giá hệ thống gợi ý phim trên bộ dữ liệu MovieLens Latest Small, đề tài sử dụng hai nhóm chỉ số: (i) MAE và RMSE đo sai số dự đoán điểm của User-

Based Collaborative Filtering; (ii) Precision@N và Recall@N đánh giá chất lượng danh sách gợi ý Top-N của cả User-Based Collaborative Filtering và Content-Based Filtering.

Hai phương pháp được so sánh trên cùng cách phân chia dữ liệu theo thời gian, cùng tập người dùng và cùng tập phim ứng viên. Dữ liệu đánh giá trong tương lai không được đưa vào quá trình xây dựng mô hình trước mốc dự đoán.

2.5.1. Nhóm chỉ số đánh giá sai số dự đoán điểm

User-Based Collaborative Filtering dự đoán điểm mà người dùng có thể chấm cho một bộ phim dựa trên lịch sử đánh giá của những người dùng tương đồng. MAE và RMSE được tính trên các cặp người dùng phim trong tập kiểm thử mà mô hình tạo ra dự đoán hợp lệ.

2.5.1.1. MAE – Mean Absolute Error

MAE đo trung bình độ lệch tuyệt đối giữa điểm dự đoán và điểm thực tế. Giá trị càng nhỏ càng tốt.

$$MAE = \frac{1}{|T|} \sum_{(u,i) \in T} |r(u,i) - \hat{r}(u,i)|$$

2.5.1.2. RMSE – Root Mean Squared Error

RMSE lấy căn bậc hai của trung bình sai số bình phương. Do bình phương sai số, RMSE nhạy hơn với các trường hợp dự đoán lệch nhiều. Giá trị càng nhỏ càng tốt.

$$RMSE = \sqrt{\frac{1}{|T|} \sum_{(u,i) \in T} (r(u,i) - \hat{r}(u,i))^2}$$

Bảng ký hiệu

Ký hiệu	Giải thích
T	Các cặp (người dùng, phim) trong Test có dự đoán hợp lệ
|T|	Số lượt đánh giá được đưa vào phép tính
r(u,i)	Điểm đánh giá thực tế của người dùng u cho phim i
r̂(u,i)	Điểm đánh giá dự đoán của mô hình cho người dùng u và phim i

Ví dụ minh họa (không phải kết quả thực nghiệm): ba lượt đánh giá có điểm thực tế

lần lượt là 5,0; 4,0; 3,0 và dự đoán là 4,5; 3,0; 3,5. Khi đó MAE = (0,5 + 1,0 + 0,5)/3 ≈ 0,667 sao và RMSE = √[(0,25 + 1,00 + 0,25)/3] ≈ 0,707 sao.

MAE và RMSE không áp dụng trực tiếp cho điểm tương đồng của Content-Based Filtering vì điểm đó không nằm trên cùng thang đo sao với rating thực tế.

2.5.2. Nhóm chỉ số đánh giá chất lượng danh sách Top-N

Content-Based Filtering xếp hạng phim theo độ phù hợp giữa vector thể loại và hồ sơ sở thích người dùng; User-Based Collaborative Filtering xếp hạng theo điểm rating dự đoán. Kết quả chung đều là danh sách Top-N, vì vậy có thể đánh giá bằng Precision@N và Recall@N.

2.5.2.1. Quy tắc phim phù hợp (Relevance Rule)

Một phim i có điểm đánh giá thực tế của người dùng u trong Test được xem là phù hợp khi điểm đó đạt ngưỡng θ. Ví dụ θ = 4,0 sao chỉ là lựa chọn minh họa; ngưỡng chính thức cần được chốt trước khi đánh giá Test.

Với phim không có rating quan sát được trong Test, chưa thể kết luận phim phù hợp hay không phù hợp. Khi tính độ đo ngoại tuyến, phim này không được tính là một lượt gợi ý đúng.

2.5.2.2. Precision@N

Precision@N cho biết trong N phim hệ thống đề xuất có bao nhiêu phim phù hợp được xác nhận bằng rating thực tế trong Test.

$$Precision@N = \frac{1}{|U|} \sum_{u \in U} \frac{|Rec_n(u) \cap Rel(u)|}{N}$$

2.5.2.3. Recall@N

Recall@N cho biết hệ thống tìm được bao nhiêu phim phù hợp trong tổng số phim phù hợp thực tế thuộc tập ứng viên được đánh giá.

$$Recall@N = \frac{1}{|U_valid|} \sum_{u \in U_valid} \frac{|Rec_n(u) \cap Rel(u)|}{|Rel(u)|}$$

Bảng ký hiệu

Ký hiệu	Giải thích
$Rec_n(u)$	Danh sách N phim do mô hình đề xuất cho người dùng u

Rel(u)	Tập phim trong Test có rating ≥ θ, đồng thời thuộc tập ứng viên hợp lệ
U	Tập người dùng đủ điều kiện tính Precision@N
U_valid	Người dùng đủ điều kiện và có ít nhất một phim trong Rel(u)
N	Độ dài danh sách đề xuất; phải thống nhất giữa hai mô hình

Ví dụ minh họa (không phải kết quả thực nghiệm): hệ thống đề xuất Top-5 = {A, B, C, D, E}, còn tập phim phù hợp trong Test là {A, C, E, F, G, H}. Ba phim A, C, E xuất hiện ở cả hai tập. Do đó Precision@5 = 3/5 = 0,60 và Recall@5 = 3/6 = 0,50.

Khi Rel(u) rỗng, Recall@N không xác định và người dùng đó được loại khỏi phép tính Recall@N trung bình; số trường hợp này phải được báo cáo riêng. Nếu không đủ N phim để đề xuất, quy tắc xử lý (ví dụ bỏ qua người dùng đó hoặc đệm bằng giá trị mặc định) phải được công bố và áp dụng giống nhau cho cả hai mô hình.

2.5.3. Quy trình đánh giá thống nhất

Ratings.csv được sắp theo timestamp và chia Train → Validation → Test bằng các mốc thời gian chung; các bản ghi có cùng thời điểm không tách qua hai giai đoạn. Mốc chia hoặc tỷ lệ phân chia cụ thể sẽ được báo cáo theo thực nghiệm thực tế.

Giai đoạn	Thực hiện	Quy tắc kiểm soát
Train	Tạo ma trận user–movie, tính tương đồng; mã hóa genres và tạo hồ sơ sở thích.	Không sử dụng rating từ Validation hoặc Test.
Validation	Thử cấu hình mô hình, đặc biệt là số láng giềng K của User-Based CF.	Chọn cấu hình trước khi xem kết quả Test.
Test	Tạo gợi ý Top-N, tính Precision@N, Recall@N; tính MAE, RMSE cho User-Based CF.	Không dùng Test để điều chỉnh mô hình hoặc chọn tham số.

Tập phim ứng viên của mỗi người dùng u tại thời điểm dự đoán gồm tất cả các phim đã xuất hiện trước mốc dự đoán nhưng chưa được người dùng đó đánh giá trong lịch

sử dùng để tạo gợi ý. Các phim phù hợp trong Test chỉ được tính nếu nằm trong tập ứng viên hợp lệ.

Trong quy ước đánh giá Top-N trên toàn bộ tập ứng viên, phim chưa có rating Test không được tính là gợi ý đúng. Điều này có thể làm Precision@N đo được thấp hơn mức độ phù hợp thực tế; vì vậy không diễn giải phim không được đánh giá là phim người dùng không thích.

2.5.4. Bảng tổng hợp các độ đo đánh giá

Độ đo	Mục đích	Giá trị	Chiều tối ưu	Áp dụng
MAE	Sai số tuyệt đối trung bình	≥ 0 (sao)	Thấp hơn	User-Based CF
RMSE	Nhạy với sai số lớn	≥ 0 (sao)	Thấp hơn	User-Based CF
Precision@N	Tỷ lệ phim gợi ý đúng trong Top-N	[0, 1]	Cao hơn	Cả hai
Recall@N	Tỷ lệ tìm được phim phù hợp	[0, 1]	Cao hơn	Cả hai

2.5.5. Lựa chọn tham số và nguyên tắc so sánh

Thành phần	Vai trò	Cách sử dụng trong đề tài
K (số láng giềng)	Siêu tham số của User-Based CF	Thử nhiều giá trị trên Validation và chọn theo tiêu chí được xác định trước.
θ (Rating Threshold)	Ngưỡng xác định phim phù hợp	Có thể tham khảo 4,0 sao; chốt và dùng chung trước khi đánh giá Test.
N (Top-N)	Độ dài danh sách gợi ý	Có thể khảo sát N = 5, 10, 20; hai mô hình so sánh tại cùng N.

Nếu mục tiêu chọn cấu hình User-Based CF là dự đoán rating thì sử dụng MAE hoặc RMSE trên Validation; nếu ưu tiên chất lượng gợi ý Top-N thì lựa chọn tiêu chí Precision@N hoặc Recall@N đã định trước. Kết quả Test chỉ dùng cho đánh giá cuối cùng.

Để so sánh công bằng, hai mô hình phải sử dụng cùng mốc chia thời gian, cùng tập

người dùng, cùng tập phim ứng viên, cùng ngưỡng θ và cùng N. Cần báo cáo số người dùng đủ điều kiện, số người dùng không có phim phù hợp trong Test và số trường hợp không thể tạo dự đoán. Chức năng "gợi ý phim tương tự" của Content-Based Filtering cần kiểm tra riêng, không gộp kết quả vào đánh giá gợi ý cá nhân hóa.

2.5.6. Kết luận

MAE và RMSE cho phép đánh giá khả năng dự đoán điểm của User-Based Collaborative Filtering; Precision@N và Recall@N là cơ sở chung để so sánh chất lượng danh sách Top-N của cả hai mô hình. Phân chia Train–Validation–Test theo thời gian và thống nhất quy tắc đánh giá giúp hạn chế rò rỉ thông tin và tăng tính khách quan của kết quả thực nghiệm.

Ghi chú về phạm vi nguồn:

Phần mô tả phương pháp, dữ liệu và chiến lược chia theo thời gian bám theo Chương 1. Các giá trị θ = 4,0, N = 5/10/20 và các ví dụ tính toán chỉ là minh họa, chưa phải tham số đã chốt hay kết quả chạy mô hình.

CHƯƠNG 3: DỮ LIỆU VÀ TIỀN XỬ LÝ DỮ LIỆU

3.1. Cấu trúc dữ liệu

3.1.1. Thu thập dữ liệu

3.1.2. Nguồn dữ liệu

Trong đề tài Ứng dụng Machine Learning vào hệ thống gợi ý phim, nhóm sử dụng bộ dữ liệu MovieLens Latest Small (ml-latest-small) do GroupLens Research thuộc Đại học Minnesota phát hành.

MovieLens là bộ dữ liệu được sử dụng phổ biến trong nghiên cứu và phát triển các hệ thống gợi ý (Recommendation Systems). Dữ liệu cung cấp lịch sử đánh giá phim của người dùng, thông tin cơ bản về phim, các thẻ mô tả và mã định danh liên kết với những cơ sở dữ liệu phim bên ngoài.

Bộ dữ liệu được thu thập từ nguồn chính thức:

GroupLens Research: https://grouplens.org/datasets/movielens/

Tệp dữ liệu: https://files.grouplens.org/datasets/movielens/ml-latest-small.zip

Nhóm lựa chọn bộ dữ liệu này vì có quy mô phù hợp với điều kiện thực hành, cấu

trúc rõ ràng và chứa các thuộc tính cần thiết để phát triển hai phương pháp gợi ý phim: User-Based Collaborative Filtering và Content-Based Filtering.

3.1.3. Thông tin bộ dữ liệu ml-latest-small

Bộ dữ liệu MovieLens Latest Small bao gồm 610 người dùng, 9.742 bộ phim và 100.836 lượt đánh giá. Điểm đánh giá có giá trị từ 0,5 đến 5,0 sao với bước tăng 0,5.

Dữ liệu được tổ chức thành bốn tệp CSV

movies.csv bao gồm chứa mã định danh phim (movieId), tên phim kèm năm phát hành (title) và chuỗi thể loại phim (genres). Tệp này là nguồn dữ liệu cốt lõi để phân tích đặc trưng nội dung.

ratings.csv bao gồm lịch sử tương tác gồm mã người dùng (userId), mã phim (movieId), điểm đánh giá (rating) và mốc thời gian đánh giá dạng Unix timestamp (timestamp). Đây là bảng dữ liệu chính để xây dựng ma trận tương tác User-Item.

tags.csv bao gồm lưu trữ các từ khóa hoặc cụm từ tự do do người dùng gán cho phim (tag), giúp bổ sung từ khóa ngữ nghĩa chi tiết bên cạnh thể loại truyền thống. links.csv cung cấp các mã khóa ngoại liên kết (movieId, imdbId, tmdbId) để kết nối với các kho dữ liệu điện ảnh lớn bên ngoài như IMDb hoặc TMDb.

Trong khuôn khổ dự án, các tệp dữ liệu được phân chia nhiệm vụ rõ ràng để hiện thực hóa hai phương pháp gợi ý User-Based Collaborative Filtering và Content-Based Filtering

User-Based Collaborative Filtering (Lọc cộng tác dựa trên người dùng): Sử dụng chủ yếu tệp ratings.csv để tính toán độ tương đồng giữa các người dùng dựa trên lịch sử chấm điểm chung, từ đó dự đoán và đề xuất phim mới.

Content-Based Filtering (Lọc dựa trên nội dung): Khai thác các thuộc tính văn bản từ movies.csv (thể loại) kết hợp với tags.csv (thẻ mô tả) để xây dựng vector đặc trưng, gợi ý những bộ phim có nội dung tương tự với sở thích trước đây của người dùng.

Tệp bổ trợ links.csv được sử dụng như cầu nối mở rộng khi cần tra cứu thêm hình ảnh poster, tóm tắt nội dung hoặc đạo diễn từ IMDb và TMDb.

3.2. Khám phá dữ liệu

3.2.1. Tải dữ liệu và Khảo sát cấu trúc

Sau khi thu thập bộ dữ liệu MovieLens Latest Small, nhóm sử dụng ngôn ngữ lập trình Python kết hợp thư viện Pandas trên môi trường Google Colab để đọc và khảo sát cấu trúc dữ liệu.

Bộ dữ liệu gồm bốn tệp chính: movies.csv, ratings.csv, tags.csv và links.csv. Nhóm sử dụng hàm pd.read_csv() để đọc các tệp CSV, phương thức head() để quan sát những bản ghi đầu tiên, thuộc tính shape để xác định kích thước dữ liệu, và phương thức info() kết hợp với thuộc tính dtypes để kiểm tra kiểu dữ liệu của từng cột. Quá trình khảo sát giúp nhóm xác định cấu trúc, quy mô, vai trò của các thuộc tính và phát hiện những vấn đề cần xử lý trước khi xây dựng hệ thống gợi ý phim.

3.2.2. Xác định quy mô và Thuộc tính dữ liệu

Nhóm sử dụng thuộc tính shape trong thư viện Pandas để xác định số dòng và số cột của từng tệp dữ liệu. Kết quả kích thước của bộ dữ liệu MovieLens Latest Small:

Bảng 1.1. Chỉ số dòng, cột Dataset

Tập dữ liệu	Số dòng	Số cột
movies.csv	9.742	3
ratings.csv	100.836	4
tags.csv	3.683	4
links.csv	9.742	3

Bảng 1.2. Tệp movies.csv

Thuộc tính	Kiểu dữ liệu	Ý Nghĩa
movieId	int64	Là mã định danh duy nhất của phim
title	object	Là tên phim thường bao gồm tên phát hành
genres	object	Thể loại phim

Bảng 1.3. Tệp ratings.csv

Thuộc tính	Kiểu dữ liệu	Ý nghĩa
userId	int64	Là mã đinh danh người dùng
movieId	int64	Là mã phim được đánh giá
rating	float64	Điểm đánh giá từ 0.5-5
timestamp	int64	Thời điểm đánh giá

Bảng 1.4. Tệp tags.csv

Thuộc tính	Kiểu dữ liệu	Ý nghĩa
userId	int64	Mã người dùng gắn thẻ
movieId	int64	Mã phim được gắn thẻ
tag	object	Từ khóa hoặc cụm từ mô tả phim
timestamp	int64	Thời điểm gắn thẻ

Bảng 1.5. Tệp links.csv

Thuộc tính	Kiểu dữ liệu	Ý nghĩa
movieId	int64	Mã phim trong MovieLens
imdbId	string	Mã phim trên IMDb
tmdbId	int64	Mã phim trên TMDb

3.2.3. Đánh giá dữ liệu khuyết thiếu và trùng lặp

3.2.3.1. Kiểm tra giá trị thiếu

Giá trị thiếu là những ô dữ liệu không có thông tin, thường được biểu diễn dưới dạng NaN hoặc NULL. Nhóm sử dụng phương thức isnull().sum() của thư viện Pandas để kiểm tra số lượng giá trị thiếu trong từng thuộc tính của bộ dữ liệu.

Quá trình kiểm tra được thực hiện trên bốn tệp dữ liệu gồm movies.csv, ratings.csv, tags.csv và links.csv nhằm xác định mức độ đầy đủ của dữ liệu trước khi tiến hành phân tích và xây dựng mô hình.

Ngoài ra, nhóm còn kiểm tra các giá trị thiếu về mặt ngữ nghĩa, chẳng hạn chuỗi (no genres listed) trong thuộc tính genres của tệp movies.csv, nhằm phát hiện những trường hợp dữ liệu không chứa thông tin hữu ích nhưng không được biểu diễn dưới dạng NaN hoặc NULL.

3.2.3.2. Kiểm tra dữ liệu trùng lặp

Dữ liệu trùng lặp là những bản ghi có nội dung giống nhau hoặc trùng nhau theo các thuộc tính định danh, có thể ảnh hưởng đến độ chính xác của quá trình phân tích.

Nhóm sử dụng phương thức duplicated().sum() của thư viện Pandas để xác định số lượng bản ghi trùng lặp hoàn toàn trong từng tệp dữ liệu. Ngoài ra, nhóm còn kiểm tra sự trùng lặp theo các thuộc tính định danh như movieId trong tệp movies.csv và links.csv, cũng như cặp thuộc tính userId, movieId trong tệp ratings.csv.

Đối với các trường hợp trùng lặp ở một số thuộc tính như tên phim (title) hoặc mã liên kết (tmdbId), nhóm tiến hành ghi nhận và phân tích để phân biệt giữa dữ liệu trùng lặp thực sự và những trường hợp có giá trị giống nhau nhưng vẫn mang ý nghĩa riêng biệt. Kết quả kiểm tra là cơ sở để nhóm xác định các vấn đề về chất lượng dữ liệu và lựa chọn phương pháp xử lý phù hợp trong giai đoạn tiền xử lý.

3.2.3.3.Ghi nhận kết quả

Bảng 2.1. ghi nhận Links.csv

Links.csv	Giá trị thiếu	Giá trị trùng
movieId	0	0
imdbId	0	0
tmdbId	8	2

Hình 2.1. Giá trị thiếu Links.csv

Dòng chứa dữ liệu thiếu: 8 dòng

	movieId	imdbId	tmdbId
624	791	0113610	<NA>
843	1107	0102336	<NA>
2141	2851	0081454	<NA>
3027	4051	0056600	<NA>
5532	26587	0092337	<NA>
5854	32600	0377059	<NA>
6059	40697	0105946	<NA>
7382	79299	0874957	<NA>

Hình 2.2. Giá trị trùng Links.csv

tmdbId trùng: 2 dòng

	movieId	imdbId	tmdbId
4169	6003	0290538	4912
9106	144606	0270288	4912

Bảng 2.2. ghi nhận Movies.csv

Movies.csv	Giá trị thiếu	Giá trị trùng
movieId	0	0
title	0	10
genres	34	0

Hình 2.3. Giá trị thiếu Movies.csv

Phim chưa xác định thể loại: 34 dòng

	movieId	title	genres
8517	114335	La cravate (1957)	(no genres listed)
8684	122888	Ben-hur (2016)	(no genres listed)
8687	122896	Pirates of the Caribbean: Dead Men Tell No Tal...	(no genres listed)
8782	129250	Superfast! (2015)	(no genres listed)
8836	132084	Let It Be Me (1995)	(no genres listed)
8902	134861	Trevor Noah: African American (2013)	(no genres listed)
9033	141131	Guardians (2016)	(no genres listed)
9053	141866	Green Room (2015)	(no genres listed)
9070	142456	The Brand New Testament (2015)	(no genres listed)
9091	143410	Hyena Road	(no genres listed)
9138	147250	The Adventures of Sherlock Holmes and Doctor W...	(no genres listed)
9178	149330	A Cosmic Christmas (1977)	(no genres lis
9217	152037	Grease Live (2016)	(no genres listed)
9248	155589	Noin 7 veljestä (1968)	(no genres listed)
9259	156605	Paterson	(no genres listed)
9307	159161	Ali Wong: Baby Cobra (2016)	(no genres listed)
9316	159779	A Midsummer Night's Dream (2016)	(no genres listed)
9348	161008	The Forbidden Dance (1990)	(no genres listed)
9413	165489	Ethel & Ernest (2016)	(no genres listed)
9426	166024	Whiplash (2013)	(no genres listed)
9448	167570	The OA	(no genres listed)
9478	169034	Lemonade (2016)	(no genres listed)
9514	171495	Cosmos	(no genres listed)
9515	171631	Maria Bamford: Old Baby	(no genres listed)
9518	171749	Death Note: Desu nôto (2006–2007)	(no genres listed)
9525	171891	Generation Iron 2	(no genres listed)
9534	172497	T2 3-D: Battle Across Time (1996)	(no genres listed)
9541	172591	The Godfather Trilogy: 1972-1990 (1992)	(no genres listed)
9562	173535	The Adventures of Sherlock Holmes and Doctor W...	(no genres listed)
9573	174403	The Putin Interviews (2017)	(no genres listed)

Hình 2.4. Dữ liệu trùng Movies.csv

Tên phim trùng nhau: 10 dòng

	movieId	title	genres
4169	6003	Confessions of a Dangerous Mind (2002)	Comedy|Crime|Drama|Thriller
9106	144606	Confessions of a Dangerous Mind (2002)	Comedy|Crime|Drama|Romance|Thriller
650	838	Emma (1996)	Comedy|Drama|Romance
5601	26958	Emma (1996)	Romance
5854	32600	Eros (2004)	Drama
9135	147002	Eros (2004)	Drama|Romance
2141	2851	Saturn 3 (1980)	Adventure|Sci-Fi|Thriller
9468	168358	Saturn 3 (1980)	Sci-Fi|Thriller
5931	34048	War of the Worlds (2005)	Action|Adventure|Sci-Fi|Thriller
6932	64997	War of the Worlds (2005)	Action|Sci-Fi

Bảng 2.3. ghi nhận Ratings.csv

Ratings.csv	Giá trị thiếu	Giá trị trùng
UserId	0	0
MoviesId	1	0
Rating	1	---
Timestamp	1	0

Tệp ratings.csv chứa 1 dòng giá trị thiếu (NaN) và khi kiểm tra đối chiếu giữa movies.csv và ratings.csv, phát hiện có 18 bộ phim chưa nhận được lượt đánh giá nào từ người dùng

Dòng chứa dữ liệu thiếu: 1 dòng

	userId	movieId	rating	timestamp
85270	554	NaN	NaN	NaN

Số dòng bị loại do thiếu dữ liệu: 1

Hình 2.6. Dữ liệu chưa đánh giá Ratings.csv

Phim chưa có lượt đánh giá: 18 dòng

	movieId	title	genres
816	1076	Innocents, The (1961)	Drama|Horror|Thriller
2211	2939	Niagara (1953)	Drama|Thriller
2499	3338	For All Mankind (1989)	Documentary
2587	3456	Color of Paradise, The (Rang-e khoda) (1999)	Drama
3118	4194	I Know Where I'm Going! (1945)	Drama|Romance|War
4037	5721	Chosen, The (1981)	Drama
4506	6668	Road Home, The (Wo de fu qin mu qin) (1999)	Drama|Romance
4598	6849	Scrooge (1970)	Drama|Fantasy|Musical
4704	7020	Proof (1991)	Comedy|Drama|Romance
5020	7792	Parallax View, The (1974)	Thriller
5293	8765	This Gun for Hire (1942)	Crime|Film-Noir|Thriller
5421	25855	Roaring Twenties, The (1939)	Crime|Drama|Thriller
5452	26085	Mutiny on the Bounty (1962)	Adventure|Drama|Romance
5749	30892	In the Realms of the Unreal (2004)	Animation|Documentary
5824	32160	Twentieth Century (1934)	Comedy
5837	32371	Call Northside 777 (1948)	Crime|Drama|Film-Noir
5957	34482	Browning Version, The (1951)	Drama
7565	85565	Chalet Girl (2011)	Comedy|Romance

3.2.4. Kiểm tra kiểu dữ liệu

Nhóm sử dụng thuộc tính dtypes và phương thức info() của thư viện Pandas để xác định kiểu dữ liệu của các thuộc tính trong bộ dữ liệu. Việc kiểm tra giúp đảm bảo các thuộc tính có kiểu dữ liệu phù hợp trước khi thực hiện các bước làm sạch, chuẩn hóa và xây dựng mô hình học máy.

Các kiểu dữ liệu chính trong bộ dữ liệu bao gồm:

integer (int64) lưu trữ các giá trị số nguyên như mã người dùng (userId), mã phim (movieId) và thời gian đánh giá (timestamp).

float (float64) lưu trữ điểm đánh giá phim (rating), có giá trị từ 0,5 đến 5,0.

object hoặc string lưu trữ các thông tin dạng chuỗi như tên phim (title), thể loại phim (genres), thẻ mô tả (tag) và mã liên kết IMDb (imdbId).

Thông qua quá trình kiểm tra, nhóm có thể xác định những thuộc tính cần chuyển đổi hoặc chuẩn hóa kiểu dữ liệu nhằm đảm bảo tính nhất quán trong quá trình tiền xử lý.

3.2.5. Kết luận quá trình khám phá dữ liệu

Qua quá trình khám phá bộ dữ liệu MovieLens Latest Small, nhóm đã xác định được cấu trúc, kích thước, kiểu dữ liệu và đặc điểm của các thuộc tính trong bộ dữ liệu.

Dữ liệu bao gồm thông tin phim, đánh giá của người dùng, các thẻ mô tả và mã liên kết phim. Trong đó, dữ liệu đánh giá đóng vai trò quan trọng trong việc xác định sở thích người dùng, còn thông tin thể loại, tên phim và thẻ mô tả hỗ trợ xây dựng hệ thống gợi ý dựa trên nội dung.

Qua quá trình đối chiếu giữa movies.csv và ratings.csv, nhóm ghi nhận 18 bộ phim chưa có lượt đánh giá từ người dùng. Đây không phải là dữ liệu bị thiếu theo dạng NaN hoặc bản ghi không hợp lệ, mà là những bộ phim chưa có lịch sử tương tác trong tập dữ liệu.

Trong phạm vi dự án, nhóm không triển khai cơ chế xử lý Cold-Start riêng biệt. Do đó, nhóm giữ nguyên các bộ phim này trong danh mục phim và không tự động tạo thêm điểm đánh giá. Những bộ phim chưa có lịch sử tương tác sẽ không có đủ thông tin để được đề xuất thông qua phương pháp User-Based Collaborative Filtering thông thường, nhưng vẫn có thể được xem xét bởi phương pháp Content-Based Filtering nếu có đặc trưng nội dung phù hợp.

Bên cạnh đó, quá trình khám phá cũng giúp nhóm phát hiện một số vấn đề về chất lượng dữ liệu như giá trị thiếu ở thuộc tính tmdbId, các bộ phim chưa xác định thể loại và những trường hợp trùng tên phim. Các vấn đề này cần được xem xét và xử lý phù hợp để đảm bảo chất lượng dữ liệu đầu vào.

Kết quả khám phá dữ liệu là cơ sở để nhóm tiếp tục thực hiện các bước làm sạch, chuẩn hóa, mã hóa đặc trưng và kết hợp dữ liệu trong giai đoạn tiền xử lý, phục

vụ việc xây dựng hệ thống gợi ý phim.

3.3. Tiền xử lý dữ liệu

3.3.1. Làm sạch dữ liệu

Sau khi hoàn thành quá trình khám phá và đánh giá chất lượng dữ liệu, nhóm tiến hành làm sạch nhằm đảm bảo tính chính xác, nhất quán và phù hợp của dữ liệu trước khi đưa vào mô hình học máy.

Nhóm sử dụng thư viện Pandas trong Python để thực hiện các thao tác làm sạch dữ liệu, bao gồm

Xử lý dữ liệu trùng lặp Sử dụng phương thức drop_duplicates() để loại bỏ các bản ghi trùng lặp hoàn toàn. Đối với những trường hợp trùng tên phim nhưng có mã định danh movieId khác nhau, nhóm giữ nguyên để tránh làm mất dữ liệu có thể mang ý nghĩa riêng biệt.

Chuẩn hóa dữ liệu dạng chuỗi Sử dụng phương thức str.strip() để loại bỏ khoảng trắng dư thừa ở đầu và cuối chuỗi, đảm bảo tính nhất quán của các thuộc tính dạng văn bản như tên phim, thể loại và thẻ mô tả.

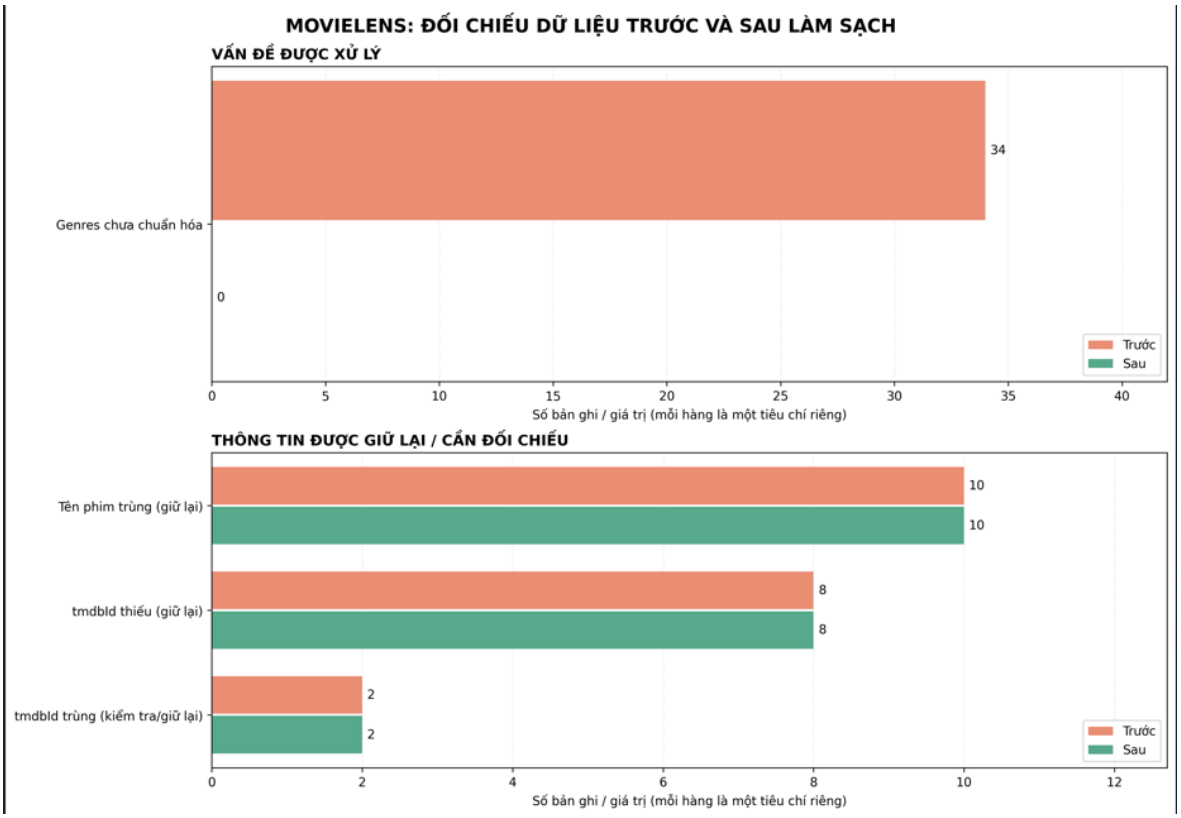
Xử lý thuộc tính genres Thay thế 34 giá trị "(no genres listed)" bằng "Unknown" nhằm thống nhất cách biểu diễn các bộ phim chưa xác định thể loại. Đây là bước xử lý giá trị thiếu về mặt ngữ nghĩa, giúp dữ liệu thuận tiện hơn cho quá trình mã hóa đặc trưng (Feature Encoding).

Kiểm tra giá trị đánh giá Kiểm tra và chỉ giữ lại các giá trị đánh giá hợp lệ trong khoảng từ 0,5 đến 5,0 với bước tăng 0,5 nhằm đảm bảo tính hợp lệ và nhất quán của dữ liệu đánh giá.

Xử lý giá trị thiếu trong links.csv Giữ nguyên 8 giá trị thiếu ở thuộc tính tmdbId vì đây là mã định danh liên kết với cơ sở dữ liệu bên ngoài, không trực tiếp tham gia vào quá trình tính toán điểm đánh giá trong phương pháp gợi ý dựa trên lịch sử đánh giá người dùng.

Sau khi thực hiện các bước làm sạch, nhóm tiến hành kiểm tra và so sánh số lượng bản ghi, giá trị thiếu và dữ liệu trùng lặp trước và sau xử lý nhằm đánh giá hiệu quả của quá trình làm sạch. Dữ liệu sau khi xử lý được lưu thành các tệp CSV riêng

biệt, phục vụ cho các bước chuyển đổi, mã hóa đặc trưng và xây dựng hệ thống gợi ý phim ở giai đoạn tiếp theo.



3.3.2. Chuẩn hoá và biến đổi dữ liệu

Trong quá trình xây dựng hệ thống gợi ý phim ứng dụng Machine Learning, chuẩn hóa và mã hóa dữ liệu là bước quan trọng nhằm đảm bảo dữ liệu đầu vào có cấu trúc thống nhất, phù hợp với yêu cầu tính toán của các mô hình. Đề tài sử dụng bộ dữ liệu MovieLens Latest Small, tập trung vào hai tệp dữ liệu chính là movies.csv và ratings.csv. Trong đó, dữ liệu phim cung cấp thông tin về tên và thể loại, còn dữ liệu đánh giá thể hiện mức độ yêu thích của người dùng đối với từng bộ phim.

Quá trình chuẩn hóa và mã hóa được thực hiện riêng đối với từng nhóm dữ liệu, nhằm phục vụ hai phương pháp Content-Based Filtering và User-Based Collaborative Filtering.

3.3.2.1. Chuẩn hóa dữ liệu phim (Movies)

Dữ liệu phim bao gồm các thuộc tính chính như movieId, title và genres. Trước

khi đưa vào mô hình, các thuộc tính được kiểm tra và chuyển về định dạng phù hợp để đảm bảo tính nhất quán trong quá trình xử lý.

Trường movieId được sử dụng làm mã định danh duy nhất cho mỗi bộ phim. Trường title được xử lý dưới dạng chuỗi ký tự, trong khi thông tin năm phát hành được trích xuất từ tên phim và lưu riêng vào trường year dưới dạng số.

Đối với những tên phim có năm phát hành gồm bốn chữ số nằm trong dấu ngoặc đơn ở cuối chuỗi, hệ thống thực hiện tách tên phim và năm phát hành thành hai thuộc tính độc lập.

Bảng ví dụ chuẩn hóa tên phim và năm phát hành

Dữ liệu ban đầu	Tên phim sau xử lý	Năm phát hành
Toy Story (1995)	Toy Story	1995
Jumanji (1995)	Jumanji	1995
Heat (1995)	Heat	1995

Việc tách năm phát hành giúp dữ liệu có cấu trúc rõ ràng hơn, đồng thời hỗ trợ quá trình thống kê, phân tích thông tin phim và hiển thị kết quả trên giao diện hệ thống.

Dữ liệu được kiểm tra các giá trị thiếu, bản ghi trùng lặp và những trường hợp không hợp lệ nhằm hạn chế ảnh hưởng đến quá trình xây dựng mô hình.

3.3.2.2. Mã hóa thể loại phim

Trong bộ dữ liệu Movies, thuộc tính genres chứa danh sách các thể loại mà một bộ phim thuộc về. Các thể loại được biểu diễn dưới dạng chuỗi ký tự và phân cách với nhau bằng dấu |.

Một bộ phim có thể thuộc nhiều thể loại khác nhau, do đó dữ liệu dạng chuỗi không phù hợp để trực tiếp thực hiện các phép tính độ tương đồng.

Để giải quyết vấn đề này, nhóm sử dụng phương pháp mã hóa nhị phân đa nhãn (Multi-Hot Encoding) nhằm chuyển đổi thông tin thể loại thành các vector đặc trưng số.

Mỗi thể loại được biểu diễn bằng một cột dữ liệu riêng biệt. Giá trị của từng cột được quy định như sau:

Giá trị 1: Bộ phim thuộc thể loại tương ứng.

Giá trị 0: Bộ phim không thuộc thể loại tương ứng.

Bảng 3.x. Ví dụ mã hóa thể loại phim

Tên phim	Action	Adventure	Animation	Comedy
Toy Story	0	1	1	1
Jumanji	0	1	0	0
Grumpier Old Men	0	0	0	1

Bảng trên minh họa một số cột thể loại, không phải toàn bộ vector đặc trưng của từng phim.

Quá trình mã hóa được biểu diễn bằng công thức:

[

x_{ij}=\begin{cases}

1 & \text{nếu phim }i\text{ thuộc thể loại }j\

0 & \text{nếu phim }i\text{ không thuộc thể loại }j

\end{cases}

]

Trong đó:

(i) là chỉ số của bộ phim.

(j) là chỉ số của thể loại.

(x_{ij}) là giá trị nhị phân thể hiện phim (i) có thuộc thể loại (j) hay không.

Sau khi mã hóa, mỗi bộ phim được biểu diễn bằng một vector đặc trưng thể loại. Ví dụ, phim *Toy Story* thuộc các thể loại Adventure, Animation, Children, Comedy và Fantasy thì các vị trí tương ứng trong vector được gán giá trị 1, những vị trí còn lại được gán giá trị 0.

Đối với các cột không cần thiết, chẳng hạn cột (Unknown) trong dữ liệu đã xử lý, nhóm có thể loại bỏ nếu không còn phục vụ mục tiêu phân tích và xây dựng mô hình.

Kết quả mã hóa giúp chuyển đổi thông tin thể loại từ dạng văn bản sang dạng số, tạo điều kiện áp dụng độ đo Cosine Similarity để xác định mức độ tương đồng

giữa các bộ phim. Đây là cơ sở quan trọng để xây dựng mô hình Content-Based Filtering, phục vụ chức năng gợi ý phim tương tự và gợi ý phim theo sở thích người dùng.

3.3.2.3. Chuẩn hóa dữ liệu đánh giá (Ratings)

Đối với dữ liệu đánh giá, các thuộc tính chính bao gồm userId, movieId, rating và timestamp. Đây là nhóm dữ liệu được sử dụng để xây dựng ma trận đánh giá người dùng – phim, phục vụ phương pháp User-Based Collaborative Filtering.

Trước tiên, nhóm thực hiện chuẩn hóa tên cột và chuyển đổi các trường dữ liệu sang kiểu phù hợp. Trong đó, userId và movieId được biểu diễn dưới dạng số nguyên, rating được biểu diễn dưới dạng số thực, còn timestamp được lưu dưới dạng thời gian Unix.

Ngoài ra, thuộc tính timestamp được chuyển đổi thêm thành datetime_utc nhằm hỗ trợ kiểm tra và phân tích dữ liệu theo thời gian.

Sau khi chuẩn hóa kiểu dữ liệu, nhóm kiểm tra các giá trị thiếu, bản ghi trùng lặp và những điểm đánh giá nằm ngoài phạm vi cho phép từ 0,5 đến 5,0. Theo kết quả tiền xử lý, tập dữ liệu Ratings có 100.836 bản ghi, không phát hiện giá trị thiếu, bản ghi trùng lặp hoàn toàn hoặc điểm đánh giá ngoài khoảng hợp lệ.

Tiếp theo, dữ liệu được sắp xếp theo thứ tự tăng dần của timestamp, sử dụng userId và movieId để duy trì thứ tự ổn định khi có nhiều bản ghi cùng thời điểm.

Theo tài liệu tiền xử lý Ratings, dữ liệu được chia theo tỷ lệ 80% cho tập huấn luyện và 20% cho tập kiểm tra theo thứ tự thời gian.

Bảng 3.x. Kết quả phân chia dữ liệu Ratings

Tập dữ liệu	Số bản ghi	Tỷ lệ
Huấn luyện	80.668	80%
Kiểm tra	20.168	20%
Tổng cộng	100.836	100%

Việc phân chia dữ liệu theo thời gian nhằm mô phỏng tình huống sử dụng lịch sử đánh giá trong quá khứ để dự đoán mức độ yêu thích của người dùng đối với phim

trong tương lai, qua đó hạn chế nguy cơ rò rỉ dữ liệu.

3.3.3. Chuẩn hóa điểm đánh giá theo người dùng

Trong thực tế, mỗi người dùng có xu hướng đánh giá phim theo những mức điểm khác nhau. Một số người thường cho điểm cao, trong khi những người khác có xu hướng đánh giá khắt khe hơn. Sự khác biệt này có thể ảnh hưởng đến kết quả tính toán độ tương đồng giữa người dùng trong phương pháp User-Based Collaborative Filtering.

Để hạn chế ảnh hưởng của sự khác biệt trong thói quen đánh giá, nhóm thực hiện phương pháp khử độ lệch điểm đánh giá theo trung bình người dùng (Mean-Centering).

Trước tiên, điểm đánh giá trung bình của từng người dùng được tính trên tập huấn luyện theo công thức:

[
\overline{r}*u=\frac{1}{|I_u|}\sum*{i\in I_u}r_{ui}
]

Trong đó:

(\overline{r}_u) là điểm đánh giá trung bình của người dùng (u).

(r_{ui}) là điểm người dùng (u) đánh giá phim (i).

(I_u) là tập các phim được người dùng (u) đánh giá trong tập huấn luyện.

(|I_u|) là số lượng phim mà người dùng (u) đã đánh giá trong tập huấn luyện.

Sau đó, điểm đánh giá được chuẩn hóa bằng cách lấy điểm đánh giá ban đầu trừ đi điểm trung bình của người dùng:

[
r'*{ui}=r*{ui}-\overline{r}_u
]

Trong đó, (r'_{ui}) là điểm đánh giá sau khi khử độ lệch.

Ví dụ, một người dùng có ba điểm đánh giá lần lượt là 3, 4 và 5. Điểm đánh giá trung bình của người dùng là:

[

\overline{r}_u=\frac{3+4+5}{3}=4
]

Sau khi chuẩn hóa, các điểm đánh giá tương ứng trở thành -1, 0 và 1. Trong đó, giá trị âm thể hiện mức đánh giá thấp hơn trung bình, giá trị 0 thể hiện mức đánh giá bằng trung bình và giá trị dương thể hiện mức đánh giá cao hơn trung bình của người dùng.

Đối với người dùng xuất hiện trong tập kiểm tra nhưng không có lịch sử đánh giá trong tập huấn luyện, nhóm sử dụng giá trị trung bình toàn tập huấn luyện làm giá trị thay thế. Theo kết quả tiền xử lý, giá trị trung bình này là 3,5085.

Phương pháp Mean-Centering giúp giảm ảnh hưởng từ sự khác biệt trong thang đánh giá của từng người dùng, đồng thời hỗ trợ việc xác định mức độ tương đồng về sở thích khi xây dựng mô hình lọc cộng tác.

3.3.4. Kết quả chuẩn hóa và mã hóa dữ liệu

Sau khi hoàn thành quá trình chuẩn hóa và mã hóa, hai nhóm dữ liệu được chuyển đổi về dạng phù hợp với các phương pháp gợi ý của đề tài.

Đối với dữ liệu Movies, tên phim và năm phát hành được tách thành các thuộc tính riêng biệt, đồng thời danh sách thể loại được mã hóa thành các vector nhị phân. Các vector này được sử dụng để tính toán độ tương đồng giữa phim với phim và giữa phim với hồ sơ sở thích người dùng trong phương pháp Content-Based Filtering.

Đối với dữ liệu Ratings, các thuộc tính được chuẩn hóa kiểu dữ liệu, kiểm tra tính hợp lệ và tổ chức theo thời gian. Điểm đánh giá được khử độ lệch theo trung bình người dùng để phục vụ quá trình tính toán độ tương đồng trong phương pháp User-Based Collaborative Filtering.

Quá trình chuẩn hóa và mã hóa dữ liệu giúp nâng cao tính nhất quán của dữ liệu đầu vào, hạn chế ảnh hưởng của các giá trị không hợp lệ và chuyển đổi dữ liệu sang dạng số phù hợp với các thuật toán Machine Learning. Đây là bước chuẩn bị quan trọng, tạo nền tảng cho việc xây dựng, huấn luyện và đánh giá hai mô hình gợi ý phim trong các giai đoạn tiếp theo.

CHƯƠNG 4: XÂY DỰNG MÔ HÌNH GỢI Ý PHIM

4.1. Chiến lược huấn luyện mô hình, tham số và siêu tham số

Trong đề tài xây dựng hệ thống gợi ý phim ứng dụng Machine Learning, nhóm triển khai hai phương pháp là Content-Based Filtering và User-Based Collaborative Filtering. Quá trình xây dựng mô hình tập trung vào việc khai thác dữ liệu đánh giá của người dùng, đặc trưng thể loại phim và điều chỉnh các siêu tham số nhằm nâng cao chất lượng danh sách phim được đề xuất.

Số lượng láng giềng (K): Đối với phương pháp User-Based Collaborative Filtering, K là số lượng người dùng có mức độ tương đồng cao nhất với người dùng mục tiêu được lựa chọn để hỗ trợ dự đoán điểm đánh giá. Nếu K quá nhỏ, kết quả dự đoán có thể phụ thuộc vào một số ít người dùng. Ngược lại, nếu K quá lớn, mô hình có thể sử dụng thêm những người dùng có sở thích ít tương đồng, làm giảm độ chính xác của kết quả gợi ý. Vì vậy, cần thử nghiệm các giá trị K khác nhau để lựa chọn cấu hình phù hợp.

Ngưỡng điểm yêu thích (Rating Threshold): Đây là giá trị được sử dụng để xác định một bộ phim có được xem là phù hợp với sở thích của người dùng hay không. Chẳng hạn, khi lựa chọn ngưỡng đánh giá là 4,0 sao, những bộ phim có điểm đánh giá từ 4,0 trở lên được xem là phim được yêu thích. Ngưỡng này phục vụ việc xác định các phim phù hợp khi xây dựng hồ sơ sở thích và đánh giá chất lượng gợi ý. Độ dài danh sách gợi ý (Top-N): Tham số N xác định số lượng bộ phim được đề xuất cho mỗi người dùng. Sau khi tính điểm phù hợp hoặc dự đoán điểm đánh giá, hệ thống sắp xếp các phim theo thứ tự giảm dần và lựa chọn N phim có điểm cao nhất. Các giá trị N có thể được khảo sát để đánh giá chất lượng danh sách gợi ý ở những độ dài khác nhau.

Chiến lược lựa chọn tham số: Dữ liệu đánh giá phim được phân chia theo thời gian thành ba tập: Training, Validation và Testing. Tập Training được sử dụng để xây dựng ma trận đánh giá, tính độ tương đồng và hình thành hồ sơ sở thích người dùng. Tập Validation được sử dụng để thử nghiệm, so sánh và lựa chọn các cấu hình tham số phù hợp. Sau khi lựa chọn cấu hình, nhóm tiến hành đánh giá kết quả cuối cùng

trên tập Testing.

Chất lượng danh sách gợi ý được đánh giá thông qua hai chỉ số Precision@N và Recall@N. Đối với phương pháp User-Based Collaborative Filtering, nhóm có thể sử dụng thêm MAE và RMSE để đánh giá sai số dự đoán điểm. Việc lựa chọn cấu hình dựa trên tập Validation giúp hạn chế tình trạng điều chỉnh mô hình trực tiếp theo tập Testing, góp phần bảo đảm tính khách quan của kết quả thực nghiệm.

4.2. Xây dựng model

CHƯƠNG 5: THỰC NGHIỆM VÀ ĐÁNH GIÁ

CHƯƠNG 6: XÂY DỰNG WEB MINH HOẠ

CHƯƠNG 7: TỔNG KẾT